

Univerzitet “Džemal Bijedić” u Mostaru
Fakultet informacijskih tehnologija



Predmet: Mašinsko učenje

Money vs Happiness

Dokumentacija projekta

Profesor :

Dr. Sc. Mirela Mabić

Student:

Lana Mustafić, IB210240

Akadska 2025/2026. godina

Mostar, septembar 2026.

CILJ MODELA

Osnovni cilj je identifikovati i matematički modelirati odnos između šest navedenih faktora i nivoa sreće, kako bi se odgovorilo na ključno istraživačko pitanje:

Da li se nivo sreće neke države može pouzdano predvidjeti na osnovu njenih ekonomskih i društvenih parametara, te da li je sam BDP dovoljan za njegovo objašnjenje?

1.2 Hipoteze rada

- **H_1:** Postoji jaka i statistički značajna pozitivna povezanost između BDP-a po glavi stanovnika (Logged GDP per capita) i ocjene sreće (Happiness score).
- **H_2:** Sam BDP nije dovoljan za preciznu predikciju sreće - socijalni, zdravstveni i institucionalni faktori imaju ključnu prediktivnu ulogu.

OPERACIONALIZACIJA I METRIKA

Istraživački element	Varijabla / Metoda	Indikator / Metrika
Ekonomsko bogatstvo	Logged GDP per capita	Pearsonov koeficijent (r), R ² score
Nacionalna sreća (Cilj)	Happiness score	Kontinuirana skala (WHR 2023)
Socijalni i ostali faktori	Social support, Freedom, Healthy life, Corruption, Generosity	Feature Importance, koeficijenti regresije
Procjena modela	Linearna regresija, Random Forest, XGBoost	5-fold CV, Test metrics (R ² , MAE, RMSE)

OPIS SKUPA PODATAKA

Analiza i modeliranje se zasnivaju na zvaničnom skupu podataka iz **World Happiness Report 2023**. Osnovne informacije o skupu podataka prikazane su u Tabeli 3.1, dok su ulazne karakteristike opisane u Tabeli 3.2.

Tabela 3.1: Osnovne informacije o skupu podataka

Stavka	Vrijednost
Izvor	World Happiness Report 2023
Godina	2023
Broj zemalja (uzorak)	137
Broj ML karakteristika (X)	6 (sve numeričke)
Ciljna varijabla (y)	Happiness score (kontinuirana numerička)

Tabela 3.2: Pregled ulaznih karakteristika modela

Karakteristika	Tip	Uloga
Logged GDP per capita	Numerička	Ekonomski faktor
Social support	Numerička	Socijalni faktor
Healthy life expectancy	Numerička	Zdravstveni faktor
Freedom to make life choices	Numerička	Institucionalni faktor
Generosity	Numerička	Socijalni faktor
Perceptions of corruption	Numerička	Institucionalni faktor

IZVOR PODATAKA

4.1 Primarni izvor podataka - WHR 2023

Primarni i jedini izvor podataka korišten u ovom projektu je **World Happiness Report 2023** koji objavljuje UN SDSN u saradnji sa Gallup World Poll-om.

Tabela 4.1: *Metapodaci primarnog izvora*

Metadatak	Opis
Naziv izvora	World Happiness Report 2023
Izdavač	SDSN / Gallup World Poll
Godina izdanja	2023.
Putanja u repozitoriju	data/WHR2023.csv
Obim skupa	137 zemalja x 21 kolona (sirovi CSV)
Uloga u projektu	Izvor za ciljnu varijablu (y) i svih 6 ulaznih karakteristika (x)

Zašto baš WHR 2023? Ova baza već spaja subjektivni osjećaj sreće sa zvaničnim ekonomskim podacima. Svi podaci su unaprijed sređeni i međunarodno uporedivi, pa nismo morali ručno peglati nazive država ili gubiti vrijeme na usklađivanje različitih godina.

4.2 Nekorišteni pomoćni podaci

U direktoriju data/raw/ nalaze se i dodatne datoteke Svjetske banke (npr. inflacija, nezaposlenost, populacija, upotreba interneta). Iako inicijalno preuzete, **ove datoteke nisu integrisane u konačni ML model** iz sljedećih razloga:

1. **Izbjegavanje šuma i redundantnosti:** WHR 2023 već sadrži standardizovane i logaritmovane podatke pripremljene od strane stručnjaka UN-a.
2. **Sprečavanje gubitka uzorka:** Spajanje vanjskih izvora dovelo bi do gubitka redova (zemalja) usljed nedostajućih podataka.
3. **Integritet evaluacije:** Zadržavanje čistog skupa od 137 zemalja obezbjeđuje potpunu konzistentnost pri unakrsnoj validaciji.

4.3 Pregled korištenih i nekorištenih varijabli

Tabela 4.2: *Koncepcijski pregled varijabli u radu*

Koncept / Varijabla	Teorijsko značenje	Status u ML modelu
Logged GDP per capita	Logaritam BDP-a po stanovniku (PPP)	KORIŠTENO (X_1)
Social support	Percepcija dostupnosti podrške	KORIŠTENO (X_2)
Healthy life exptectancy	Očekivani broj godina zdravog života	KORIŠTENO (X_3)
Freedom to make choices	Percepcija lične slobode	KORIŠTENO (X_4)
Generosity	Mjera velikodušnosti	KORIŠTENO (X_5)
Perceptions of corruption	Percepcija korupcije	KORIŠTENO (X_6)
Happiness score	Subjektivna procjena života	KORIŠTENO (Cilj - y)
Unemployment / Inflation	Makroekonomski indikatori	Nije korišteno (samo u data/raw)
Internet usage / Population	Tehnologija I demografija	Nije korišteno (samo u data/raw)
Human Development Index (HDI)	Kompozitni indeks razvoja UN-a	Nije korišteno

UCITAVANJE PODATAKA

Prva faza realizacije obuhvata učitavanje, validaciju i provjeru strukture skupa podataka primjenom biblioteke pandas.

5.1 Arhitektura učitavanja (src/data_loader.py)

Radi postizanja modularnosti i sprječavanja grešaka u putanjama, učitavanje je inkapsulirano unutar centralizovanog modula src/data_loader.py.

```

from pathlib import Path
import pandas as pd

DEFAULT_DATA_PATH = Path(__file__).resolve().parents[1] / "data" / "WHR2023.csv"

def load_raw_data(path: Path | str | None = None) -> pd.DataFrame:
    """Učitava sirove WHR 2023 podatke sa zadate putanje."""
    data_path = Path(path) if path else DEFAULT_DATA_PATH
    if not data_path.exists():
        raise FileNotFoundError(f"Dataset nije pronađen na putanji: {data_path}")
    return pd.read_csv(data_path)

```

5.2 Razdvajanje modela: ML vs. EDA scenarij

U projektu su definisana dva odvojena puta učitavanja podataka u zavisnosti od njihove namjene:

- **ML put (load_for_modeling()):** Podaci se učitavaju bez ručne popune nedostajućih vrijednosti. Nedostajuće vrijednosti se namjerno zadržavaju kako bi ih komponenta SimpleImputer obradila unutar Scikit-Learn (*Pipeline*) isključivo na trening skupu, čime se u potpunosti sprječava **curenje podataka (data leakage)**.
-
- **EDA i Dashboard put (load_and_prepare()):** Podaci se učitavaju uz globalnu imputaciju srednjom vrijednošću (*mean*), što je namijenjeno za eksploratornu analizu u Jupyter notebooku i interaktivni prikaz u Streamlit aplikaciji.
-

5.3 Inicijalna verifikacija strukture

Nakon učitavanja izvršene su automatske provjere strukture i integriteta skupa podataka.

Tabela 5.1: Rezultati inicijalne provjere skupa podataka

Pandas metoda / Atributa	Svrha i rezultat na WHR2023.csv
df.shape	Dimenzionalnost matrica: 137 redova (zemalja) i 21 kolona
df.head ()	Vizuelna provjera ispravnosti zaglavlja i separatora
df.info ()	Prikaz tipova podataka (float64, object) i popunjenosti

df.isna ().sum ()	Detekcija nedostajućih vrijednosti (utvrđen 1 NaN u Healthy life expectancy)
Df[“Country name”].nunique ()	Potvrda jedinstvenosti: 137 jedinstvenih zemalja (bez duplikata)

ČIŠĆENJE I PRETPROCESIRANJE PODATAKA

Baza je izuzetno dobro popunjena - od ukupno 137 zemalja, zabilježena je samo jedna nedostajuća vrijednost (NaN) i to u koloni Healthy life expectancy (manje od 0.73% uzorka).

Nedostajući podatak je popunjen srednjom vrijednošću (*Mean Imputation*), uz pažljivo odvojen pristup za ML i analitiku:

1. **Za ML modele (Sprečavanje *Data Leakage*-a):** Imputacija se radi unutar scikit-learn biblioteke koristeći SimpleImputer(strategy="mean"). Srednja vrijednost se računa **isključivo na trening skupu** (fit), a zatim samo primjenjuje na testni skup (transform).
2. **Za EDA i Dashboard:** Funkcija handle_missing_values() popunjava nedostajuću vrijednost nad cijelim skupom odjednom, kako bi se grafikoni i tabele u izveštajima i na *dashboardu* mogli nesmetano prikazati.

```
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.linear_model import LinearRegression

# Standardni ML Pipeline u projektu
model_pipeline = Pipeline([
    ("imputer", SimpleImputer(strategy="mean")),
    ("model", LinearRegression())
])
```

6.2 Selekcija karakteristika (*Feature Selection*)

Od ukupno 21 kolone u sirovom CSV-u, funkcija prepare_features() vrši redukciju na 10 ključnih varijabli.

Pomoćne kolone poput Explained by: ... su uklonjene kako bi se izbjeglo **cirkularno rezonovanje**, jer predstavljaju direktnu dekompoziciju ocjene sreće.

Tabela 8.1: *Struktura odabranih kolona u projektu*

Kategorija kolona	Nazivi kolona	Uloga u analizi
Ciljna varijabla (y)	Happiness score	Kontinuirani izlaz koji model predviđa
Ulazne karakteristike (X)	Logged GDP per capita Social support Healthy life expectancy Freedom to make life choices Generosity Perceptions of corruption	Skup od 6 socio-ekonomskih prediktora
Metapodaci	Country name, Regional indicator, iso alpha	Identifikatori za filtriranje i vizuelizaciju (ne ulaze u ML model)

6.3 Validacija i finalne matrice (X i y)

Prije slanja u modele, sprovedene su sljedeće provjere:

- **Verifikacija tipova:** Svih 6 prediktora i ciljna varijabla verifikovani su kao float64 tipovi.
- **Mapiranje i fleksibilnost:** Kolona Ladder score se automatski preimenuje u Happiness score radi kompatibilnosti sa starijim verzijama skupa.
- **Priprema matrica:** Podaci se razdvajaju u dvodimenzionalnu matricu osobina X dimenzija (137, 6) i vektor ciljne varijable y dužine 137.

```
# Finalni oblik matrica spremnih za ML pipeline
X = df[[
    'Logged GDP per capita',
    'Social support',
    'Healthy life expectancy',
    'Freedom to make life choices',
    'Generosity',
    'Perceptions of corruption'
]] # Matrica dimenzija (137, 6), tip: float64

y = df['Happiness score'] # Vektor dimenzije (137,), tip: float64
```

EKSPLOATORNA ANALIZA PODATAKA (EDA)

Eksploratorna analiza (EDA) otkriva strukturu, raspodjele, multikolinearnost i klastere unutar skupa podataka WHR2023.csv. Analiza je mapirana na 8 ključnih slika (*Figure 1 – 8*).

7.1 Distribucija ciljne varijable (Figure 1)

Analiza distribucije zavisne varijable Happiness score (skala 0–10) pokazuje:

- **Simetrična distribucija:** Zvonolik oblik sa srednjom vrijednošću ≈ 5.53 i medijanom ≈ 5.68 .
- **Raspon:** Najniža ocjena je 1.85 (Afganistan), a najviša 7.80 (Finska).
- **Implikacija za ML:** Odsustvo ekstremnog zakrivljenja omogućava direktnu primjenu linearne regresije i RMSE funkcije gubitka bez potrebe za logaritamskom transformacijom ciljne varijable y.

7.2 Korespondencija i multikolinearnost (Figure 2 & Figure 3)

Pearsonova analiza korelacije (r) i Boxplot analiza identifikuju ključne prediktore i raspodjele:

Tabela 7.1: Pearsonov koeficijent korelacije u odnosu na Happiness score

Karakteristika (X)	Pearsonov r	Zapažanje i struktura
Logged GDP per capita	≈ 0.78	Najsnažniji pozitivni predictor sreće
Social support	≈ 0.75	Snažab uticaj socijalne mreže; visoka zbijenost (>0.80)

Healthy life expectancy	≈ 0.74	Visoka korelacija sa BDP-on ($r > 0.80$)
Freedom to make life choices	≈ 0.60	Umjereno snažan institucionalni predictor
Perceptions of corruption	≈ -0.47	Negativna korelacija; prisutan veći broj autlajera
Generosity	≈ 0.04	Slaba linearna povezanost, izraženija asimetrija

Metodološka napomena: BDP i očekivani životni vek su u jakoj korelaciji ($r > 0.80$). To znači da imamo problem **multikolinearnosti**, pa je skroz opravdano što koristimo regularizaciju (Ridge/Lasso) i modele bazirane na stablima odluke.

7.3 Nelinearnost i Easterlinov paradoks (Slika 4)

- **Grafik raspršenosti (Scatter plot)** odnosa BDP-a i sreće lepo prikazuje princip *opadajućih prinosa*: skok iz niskog u srednji BDP donosi ogroman porast u sreći, dok se na visokim nivoima bogatstva taj efekat "popeglat" i stane (saturacija).
- Pošto je BDP u bazi već **logaritmovan** (Logged GDP per capita), ovaj odnos je uspešno linearizovan kako bi regresioni modeli mogli normalno da rade sa njim.

7.4 Evaluacija modela i važnost osobina (Slika 5 i Slika 6)

- **Performanse (Slika 5):** Obična i Ridge linearna regresija daju najbolje rezultate na testnom skupu ($R^2 \approx 0.75 - 0.77$). Kompleksnija stabla lagano preprilagođavaju (*overfitting*) jer nam je uzorak prilično mali ($N=137$).
- **Važnost varijabli (Slika 6):** Izlaz iz Random Forest-a i XGBoost-a jasno pokazuje da priči dominiraju dve stvari: BDP po glavi stanovnika (nosi preko 40% uticaja) i socijalna podrška (Social support, sa oko 25%).

7.5 Segmentacija zemalja — K-Means klasterovanje (Slika 7 i Slika 8)

- **Bira se broj klastera (Slika 7):** *Elbow* metoda (prelom na WCSS krivi) i *Silhouette* score nedvosmisleno pokazuju da je najbolje podeliti podatke na **K=3** klastera.
- **Prostorna segmentacija (Slika 8):**
 - **Klaster 0 (Nizak razvoj):** Države sa niskim BDP-om i slabom ocenom sreće (uglavnom subsaharska Afrika i krizna područja).
 - **Klaster 1 (Srednji razvoj):** Zemlje u razvoju (Latinska Amerika, Jugoistočna Evropa, deo Azije).
 - **Klaster 2 (Visok razvoj):** Razvijene ekonomije (Nordijske zemlje, Zapadna Evropa, Severna Amerika) sa visokim BDP-om i jakom socijalnom mrežom.

ANALIZA KORELACIJE

Linearne povezanosti između ulaznih varijabli (X) i cilja (y) kvantifikovane su **Pearsonovim koeficijentom korelacije (r)**.

8.1 Empirijski rezultati

Tabela 8.1: *Pearsonov koeficijent korelacije u odnosu na Happiness score*

Socio-ekonomski faktor (X)	Pearsonov koeficijent (r)	Smjer i jačina povezanosti
Social support	+0.835	Izuzetno jaka pozitivna korelacija
Logged GDP per capita	+0.784	Snažna pozitivna korelacija
Healthy life expectancy	+0.746	Snažna pozitivna korelacija
Freedom to make life choices	+0.663	Umjereno jaka pozitivna korelacija
Generosity	+0.044	Zanemarljiva / Nulta korelacija
Perceptions of corruption	-0.472	Umjereno jaka negativna korelacija

8.2 Šta nam govore ovi faktori?

1. **Social support (r = 0.835):** Ubjedljivo najjači pojedinačni faktor. Pokazuje da nam je osjećaj da se imamo na koga osloniti u životu važniji za sreću čak i od samog novca.
2. **Logged GDP per capita (r = 0.784):** Glavni materijalni oslonac blagostanja. Ovo direktno potvrđuje našu prvu hipotezu (H₁) - ekonomski razvoj jeste ključan temelj.
3. **Healthy life expectancy (r = 0.746):** Zdravlje i očekivani životni vijek u stopu prate to koliko su ljudi zadovoljni životom.
4. **Freedom to make choices (r = 0.663):** Lična sloboda i mogućnost izbora predstavljaju jako važan nematerijalni faktor.
5. **Perceptions of corruption (r = -0.472):** Očekivano negativna korelacija — što je percepcija korupcije veća, povjerenje opada, a s njim i opšta sreća.
6. **Generosity (r = 0.044):** Ovdje praktično nema nikakve linearne veze. To koliko su ljudi u prosjeku filantropski nastrojeni na nivou države ne utiče direktno na opštu ocjenu sreće.

8.3 Važno upozorenje: Korelacija nije isto što i kauzalnost!

To što neki faktori imaju visoku korelaciju sa srećom ne znači automatski da oni direktno uzrokuju sreću. Za to postoje tri glavna razloga:

- **Skrivene varijable (*Confounding Variables*):** Bogatije zemlje obično "u paketu" imaju i bolje zdravstvo, jaču vladavinu prava i stabilnije institucije, pa je teško razdvojiti šta tačno utiče na šta.
- **Jedna tačka u vremenu (*Cross-section*):** Podaci su samo iz 2023. godine. Prikazuju trenutno stanje među zemljama, a ne kako se situacija mijenja kroz vrijeme unutar jedne države.
- **Obrnuta uzročnost (*Reversed Causality*):** Uzročni smjer može biti obrnut — možda sretniji i zdraviji ljudi prave jaču ekonomiju, a ne samo obrnuto.

Zaključak: Korelacija nam daje odličnu osnovu za prave prediktivne ML modele, ali je ne smijemo tumačiti kao slijepi dokaz uzroka i posljedice.

ANALIZA ODNOSA GDP-A I NACIONALNE SREĆE (GDP VS. HAPPINESS)

Kako bismo provjerili koliku stvarno snagu ima sam BDP u prognoziranju sreće, napravili smo jednostavan eksperiment sa univarijantnom linearnom regresijom (OLS model). Jedini ulazni podatak (X) bio je logaritmovani BDP po glavi stanovnika (Logged GDP per capita), dok je izlaz (y) bio indeks sreće (Happiness score).

9.1 Šta nam govori model sa samim BDP-om?

- **Objašnjen varijabilitet (61.5%):** Sam BDP po glavi stanovnika objašnjava više od dvije trećine razlika u nivou sreće među 137 posmatranih zemalja.
- **Potvrda prve hipoteze (H₁):** Ovo direktno potvrđuje da je BDP odlična polazna tačka. Ekonomski razvoj stvara neophodne osnove - infrastrukturu, zdravstvo, obrazovanje i materijalnu sigurnost.

9.2 Zašto sam BDP ipak nije dovoljan? (Neobjašnjenih 38.5%)

Preostalih 38.5% varijanse jasno pokazuje da novac nije jedini faktor. Najbolji dokaz za to su odstupanja (*outlieri*) u podacima:

- **Visok BDP, a skromnija sreća:**
 - **Hong Kong:** Sa BDP-om u samom svetskom vrhu (10.966), ocjena sreće je ispod medijane (5.308) zbog ogromnih troškova života, stresa i političkih tenzija.
 - **Bocvana i Turska:** Imaju solidnu ekonomiju, ali nižu ocjenu sreće zbog nejednakosti, inflacije i problema u institucijama.
- **Skromniji BDP, a visoka sreća:**

- **Kosovo i Nikaragva:** Iako imaju BDP znatno ispod prosjeka, bilježe visoke ocjene sreće (>6.25), čime nadmašuju mnoge bogatije države.
- **Gvatemala, El Salvador i Honduras:** Latinskoamerički primjer gdje jačina porodičnih i društvenih veza (Social support) nadoknađuje ekonomski deficit.

9.3 Prelazak na kompletan model (Svis 6 faktora)

Ovaj neobjašnjeni dio od 38.5% direktno potkrepljuje i **Drugu hipotezu (H₂)**: sam BDP nije dovoljan jer socijalni i institucionalni faktori igraju ogromnu ulogu. Uvođenjem preostalih 5 varijabli u multivarijantni model, preciznost predikcije drastično raste.

Tabela 9.1: Poređenje univarijantnog i multivarijantnog modela

Model	Ulazne karakteristike (X)	R2 Score	Smanjenje neobjašnjenje varijanse
Jednostavni OLS	Samo Logged GDP per capita	0.615	Bazna linija (38.5% neobjašnjeno)
Finalni ML Model (LR)	Svih 6 socio-ekonomskih faktora	0.780	Skok na 78.0% (Samo 22.0% neobjašnjeno)

9.4 Zaključak

1. **BDP je temelj, ali ne i krov blagostanja:** Ekonomski rast stvara neophodnu materijalnu osnovu (≈61.5%), ali bez socijalne podrške, zdravlja i slobode, sam novac ne može garantovati visoku ocjenu sreće.
2. **Sinergija ekonomije i društva:** Kada u model pored BDP-a dodamo i nematerijalne faktore, objašnjeni varijabilitet skače za dodatnih **16.5%** (sa 0.615 na 0.780).
3. **Poruka za kreatore politika:** Sam goli rast BDP-a neće automatski usrećiti društvo ukoliko se u isto vrijeme zanemare jačanje društvenog povjerenja, borba protiv korupcije i zaštita ljudskih sloboda.

MODELI MAŠINSKOG UČENJA

U ovom projektu primijenjena su tri algoritma mašinskog učenja za predikciju kontinuirane varijable Happiness score. Odabrani modeli pokrivaju spektar od jednostavnijih, parametarskih linearnih modela do složenijih ansambl metoda baziranih na stablima odluke.

10.1 Linearna regresija (*Linear Regression*)

- **Uloga i postavke:** Koristeći `LinearRegression(fit_intercept=True)` iz `scikit-learn` biblioteke, ovaj algoritam je postavljen kao bazni model (*baseline*).
- **Prednosti i mane:**
 - **Prednosti:** Izuzetno je jednostavna za interpretaciju, brza, nema hiperparametara za podešavanje i vrlo je otporna na *overfitting* na malim skupovima podataka ($N=137$).
 - **Mane:** Podrazumijeva strogo linearnu vezu i osjetljiva je na multikolinearnost.
- **Rezultati:** Ostvarila je najbolje performanse generalizacije na testnom skupu ($R^2 \approx 0.780$, $RMSE \approx 0.51$). Ovo dokazuje da je odnos između socio-ekonomskih faktora i sreće na nivou država u svojoj osnovi pretežno linearan.

10.2 Random Forest Regressor

- **Uloga i postavke:** Odabran je kako bi se ispitalo postoje li nelinearni odnosi u podacima. Postavke: `RandomForestRegressor(n_estimators=100, random_state=42)`.
- **Prednosti i mane:**
 - **Prednosti:** Usješno hvata nelinearne veze bez potrebe za transformacijom varijabli, otporan je na autlajere i sam izračunava važnost osobina (*Feature Importance*).
 - **Mane:** Sklon je blagom preprilagođavanju (*overfitting*) na malim uzorcima i ne može vršiti ekstrapolaciju van opsega trening podataka.
- **Rezultati:** Pokazao je visoku tačnost na trening skupu ($R^2 > 0.92$), ali slabiju generalizaciju na testnom skupu ($R^2 \approx 0.728$, $RMSE \approx 0.57$) jer je delimično "zapamtio" specifičnosti malog broja trening primera.

10.3 XGBoost Regressor (*Extreme Gradient Boosting*)

- **Uloga i postavke:** Odabran radi maksimalne prediktivne snage uz ugrađenu L1/L2 regularizaciju. Postavke: `XGBRegressor(n_estimators=100, learning_rate=0.05, max_depth=3, random_state=42)`.
- **Prednosti i mane:**
 - **Prednosti:** Izuzetno brz algoritam sa odličnom ugrađenom regularizacijom i automatskim rukovanjem nedostajućim vrijednostima.
 - **Mane:** Dosta je osjetljiv na izbor hiperparametara i teži preprilagođavanju kada je uzorak mali ($N < 200$).
- **Rezultati:** Bio je stabilniji od Random Forest-a zahvaljujući regularizaciji i ograničenoj dubini stabala ($\text{max_depth}=3$), ostvarivši $R^2 \approx 0.745$ i $RMSE \approx 0.55$. Ipak, i dalje blago zaostaje za Linearnom regresijom primarno zbog ograničene veličine samog skupa podataka.
-

10.4 Sumarni pregled i poređenje modela

Tabela 10.1: Komparacija performansi modela na testnom skupu

Model	Tip algoritma	R2 Score (Test)	RMSE (Test)	Glavni razlog performansi
Linear Regression	Parametarski (OLS)	0.780	0.51	Pretežno linearan karakter varijabli na malom uzorku
XGBoost Regressor	Boosting ansambl	0.745	0.55	Snažan algoritam, ugrađena regularizacija ublažava overfitting
Random Forest	Bagging ansambl	0.728	0.57	Izraženiji overfitting – stable previse detaljno pamte trening skup

EVALUACIJA I POREĐENJE MODELA

Procjena performansi primijenjenih modela mašinskog učenja sprovedena je nad *holdout* testnim skupom (izdvojenih 20% podataka), koristeći tri standardne metrike za regresiju:

- **Koeficijent determinacije (R^2):** Pokazuje koji procenat varijanse ciljne varijable (Happiness score) naš model usijpešno objašnjava (vrijednost se kreće u opsegu [0, 1]).
- **Srednja apsolutna greška (MAE):** Prikazuje prosječno apsolutno odstupanje predviđenih ocjena sreće od njihovih stvarnih vrijednosti.
- **Korijen srednje kvadratne greške (RMSE):** Slično kao i MAE, ali jače kažnjava (*penalizuje*) veća odstupanja, čime daje bolji uvid u veličinu tipičnih, krupnijih grešaka.

13.1 Konačna zbirna tabela performansi

Tabela 11.1: Rezultati evaluacije modela na testnom skupu

Model	Test R2	Test MAE	Test RMSE	Status/Napomena
Linear Regression	0.780	0.406	0.512	Pobjednički model (Najbolja generalizacija)
XGBoost Regressor	0.745	0.435	0.551	Regularizovani ansambl (Stabilne performanse)
Random Forest Regressor	0.728	0.452	0.573	Blagi overfitting na trening skupu

11.2 Detaljna analiza i interpretacija rezultata

- **Dominacija Linearne regresije ($R^2 = 0.780$, $MAE = 0.406$):** Linearna regresija ostvarila je najbolju tačnost na testnom skupu, sa prosječnom greškom predikcije od svega 0.406 poena na skali od 0 do 10. S obzirom na to da se ukupne ocjene sreće u

svijetu kreću u rasponu od 1.85 do 7.80, odstupanje od svega ≈ 0.4 predstavlja izuzetno preciznu procjenu.

- **Zašto su složeniji modeli podbacili?** Ansambl modeli bazirani na stablima odluke (Random Forest i XGBoost) traže znatno veće količine podataka ($N > 1000$) kako bi efikasno naučili nelinearne odnose. Na ovako malom uzorku od samo 137 zemalja, jednostavni linearni model djeluje kao prirodna regularizacija koja uspješno sprečava preprilagođavanje (*overfitting*).

ANALIZA ZNAČAJA KARAKTERISTIKA (FEATURE IMPORTANCE)

Dok nam koeficijenti linearne regresije (β) pokazuju samo smer i nagib prave za svaku varijablu, analiza važnosti osobina (*Feature Importance*) u ansambl modelima (Random Forest i XGBoost) govori nešto mnogo konkretnije: koliko svaka varijabla stvarno doprinosi smanjenju neodređenosti (redukciji varijanse) pri razdvajanju podataka u čvorovima stabala.

12.1 Rangiranje varijabli po uticaju na predikciju

Nakon optimizacije modela, izračunali smo prosječan relativni značaj svih ulaznih faktora. Rezultati jasno pokazuju da pričom ubedljivo dominiraju dva ključna stuba blagostanja:

Tabela 12.1: Rang socio-ekonomskih varijabli prema relativnom značaju

Rang	Socio-ekonomski factor(X)	Relativni značaj (Udio)	Primarna uloga u modelu
1.	Social support	$\approx 40\% - 45\%$	Najjači pojedinačni prediktor
2.	Logged GDP per capita	$\approx 30\% - 35\%$	Drugi najvažniji faktor
3.	Healthy life expectancy	$\approx 10\% - 12\%$	Tercijarni stabilizacijski faktor
4.	Freedom to make life choices	$\approx 6\% - 8\%$	Srednji nematerijalni uticaj
5.	Perceptions of corruption	$\approx 3\% - 5\%$	Sekundarni institucionalni uticaj
6.	Generosity	$\approx 1\% - 2\%$	Marginalni uticaj

12.2 Detaljna interpretacija vodećih prediktora

1. **Socijalna podrška (Social support):** Modeli zasnovani na stabilima odluke dodijelili su ubjedljivo najveću težinu ovoj varijabli. Prilikom podjele podataka u čvorovima, socijalna podrška najefikasnije smanjuje varijansu u ocjeni sreće. Ovo još jednom potvrđuje da su osjećaj pripadnosti i sigurnost u zajednici primarni uslov blagostanja.
2. **Ekonomsko bogatstvo (Logged GDP per capita):** Zauzima drugo mjesto po važnosti i osigurava neophodnu materijalnu osnovu (stanovanje, infrastrukturu i pokrivanje osnovnih životnih potreba). U kombinaciji sa socijalnom podrškom, ova dva faktora nose preko **70% ukupne prediktivne snage** cijelog modela.

12.3 Komparativna sinteza: Feature Importance vs. Korelaciona analiza

Rezultati dobijeni iz nelinearnih modela mašinskog učenja i klasične parametarske korelacije pokazuju savršeno poklapanje i potpunu metodološku konzistentnost:

- **Potvrda prvog mjesta:** U Pearsonovoj korelaciji, Social support ima najviši koeficijent ($r = 0.835$), što su potpuno potvrdili i Random Forest i XGBoost modeli (gdje nosi $\approx 42\%$ važnosti).
- **Potvrda drugog mjesta:** Logged GDP per capita drži drugo mjesto u obje analize ($r = 0.784$, uz $\approx 33\%$ udjela u modelima stabala).
- **Potvrda marginalnih faktora:** Varijabla Generosity ima zanemarljivu linearnu povezanost ($r = 0.044$), što se direktno odrazilo i na njeno minimalno učešće u odlukama stabala ($< 2\%$).

12.4 Implikacije za redukciju dimenzionalnosti

- **Robustnost modela:** Poklapanje dvije potpuno različite metodologije (linearne korelacije i Gradient Boostinga) dokazuje da dobijeni rezultati nisu slučajni artefakt nekog specifičnog algoritma, već odražavaju stvarnu strukturu podataka u WHR2023 skupu.
- **Optimizacija resursa:** Ukoliko bismo željeli napraviti brzu procjenu nivoa sreće za neke nove regione, prikupljanje podataka o samo tri varijable (Social support, Logged GDP per capita i Healthy life expectancy) omogućava nam da pokrijemo preko **85% prediktivnog kapaciteta** cijelog modela.

NENADGLEDANO UČENJE: K-MEANS KLASSTERIZACIJA

Pored modela nadgledanog učenja za prognoziranje Happiness score-a, primijenila sam i tehnike nenadgledanog učenja (*Unsupervised Learning*). Cilj je bio da otkrijem skrivenu strukturu i prirodne grupacije među zemljama bez korištenja unaprijed definisanih oznaka.

13.1 Svrha i teorijski koncept K-Means algoritma

K-Means je algoritam baziran na centroidima koji iterativno smanjuje sumu kvadratnih odstupanja unutar klastera (*Within-Cluster Sum of Squares - WCSS*).

Odabrali smo ga zbog njegove računske efikasnosti i jednostavne interpretacije pri radu sa kontinuiranim socio-ekonomskim pokazateljima.

13.2 Pretprocesiranje: Z-score standardizacija

Pošto se K-Means direktno oslanja na Euklidsku udaljenost, varijable sa većim rasponom vrijednosti (npr. Logged GDP per capita u rasponu [7, 11] u odnosu na Social support u rasponu [0, 1]) vještački bi dominirale u proračunu. Zbog toga smo prvo sproveli Z-score standardizaciju svih varijabli.

13.3 Određivanje optimalnog broja klastera (K)

Da bismo izabrali najbolju vrijednost za hiperparametar K, iskoristili smo dvije komplementarne kvantitativne metode:

- **Metoda lakta (*Elbow Method*):** Posmatranjem pada WCSS-a za opseg K in [2, 8], jasan prelom krive ("lakat") uočava se tačno na **K = 3**.
- **Silhouette analiza (*Silhouette Score*):** Mjeri odnos kohezije unutar klastera (a_i) i odvojenosti od susjednih klastera (b_i).
- Silhouette koeficijent dostiže svoj globalni maksimum upravo za **K = 3** ($S \approx 0.35 - 0.40$), čime je nedvosmisleno potvrđena podjela WHR2023 skupa na tri glavne makro-kategorije.

13.4 Profilisanje i interpretacija klastera

Analiza dobijenih centroida po klasterima otkriva jasnu globalnu socio-ekonomsku podjelu:

Tabela 13.1: Socio-ekonomski profil formiranih klastera ($K=3$)

Profilna karakteristika	Klaster 0: Nizak razvoj	Klaster 1: Tranzicijski pojas	Klaster 2: Visok razvoj
Prosječan Happiness score	$\approx 4.10 - 4.30\$$	$\approx 5.50 - 5.80\$$	$\approx 6.80 - 7.20\$$
Logged GDP per capita	Nizak	Srednji	Izrazito visok
Social support	Skroman	Srednji / Dobar	Izuzetno visok
Healthy life expectancy	Najniži raspon	Umjeren / Stabilan	Najviši raspon
Perceptions of corruption	Visoka	Varijabilna	Primjetno niža
Tipični predstavnici	Subsaharska Afrika, konfliktne zone	Latinska Amerika, JIE, dio Azije	Nordijske zemlje, Zapadna Evropa

Evo prepravljenog teksta u ujednačenom, jasnom i pismenom studentskom stilu (idealno za završne sekcije rada):

13.5 Distribucija zemalja i sinteza rezultata

- **Klaster 0 (Kriza blagostanja):** Obuhvata zemlje sa višestrukim strukturnim problemima (nizak BDP, slabiji zdravstveni sistem i slabe institucije), koje formiraju zbijenu grupu na samom dnu socio-ekonomskog spektra.
- **Klaster 1 (Tranzicijski pojas):** Najbrojnija i prilično heterogena grupa. Obuhvata države u razvoju koje bilježe napredak u BDP-u, ali i dalje kaskaju u pogledu institucionalnog povjerenja i socijalne zaštite.
- **Klaster 2 (Zlatni standard):** Obuhvata najsretnije nacije (predvođene nordijskim zemljama) koje odlikuje savršena sinergija visokog BDP-a, jake socijalne mreže, ličnih sloboda i niske korupcije.

Sinteza: K-Means klasterizacija je potpuno autonomno - bez ikakvog pristupa ciljnoj varijabli *Happiness score* - grupisala zemlje u kategorije koje se savršeno poklapaju sa rasponima indeksa sreće. Ovo dokazuje da je subjektivni osjećaj sreće zapravo direktna manifestacija objektivnih socio-ekonomskih struktura.

INTERAKTIVNI DASHBOARD ZA ANALIZU I VIZUELIZACIJU (STREAMLIT + PLOTLY)

U sklopu projekta razvijena je interaktivna web aplikacija (app.py) koja omogućava intuitivnu eksploraciju, vizuelizaciju i komparativnu analizu podataka iz *World Happiness Report 2023*. Dashboard služi kao centralni analitički alat namijenjen stručnoj javnosti i donosiocima odluka za brz i lak uvid u socio-ekonomske pokazatelje.

14.1 Tehnološki stek i softverska arhitektura

Aplikacija se oslanja na savremeni Python ekosistem za *Data Science*:

- **Streamlit (app.py):** *Open-source* okvir za brzu izgradnju interaktivnih web interfejsa direktno iz Python koda. Upravlja stanjem aplikacije, rasporedom komponenata (*layout*) i reakcijama na korisničke komande.
- **Plotly Express & Graph Objects:** Generišu dinamičke, vektorske vizuelizacije. Omogućavaju potpunu interaktivnost - *hover* prikaz tačnih vrijednosti na prelaz mišem, zumiranje, panovanje i izvoz slika u visokoj rezoluciji.
- **Modularna pozadina (src/):** Aplikacija direktno poziva funkcije iz modula *src/data_loader.py* i *src/preprocessing.py*, čime se izbjegava ponavljanje koda i osigurava njegova modularnost.

14.2 Metodološka napomena: Prikaz stvarnih podataka vs. ML predikcije

Dashboard je striktno projektovan kao alat za Eksploratornu analizu podataka (EDA) i prikazuje isključivo stvarne, empirijski potvrđene podatke iz WHR2023.csv baze, bez generisanja predikcija u realnom vremenu.

1. **Integritet analize:** Zadržavanje aplikacije u domenu deskriptivne statistike sprječava miješanje istorijskih činjenica sa procjenama ili greškama mašinskih modela ($RMSE \approx 0.51$).
2. **Performanse i odziv:** Izbjegavanjem dinamičkog treniranja i transformacija unutar web interfejsa postiže se trenutno renderovanje grafikona pri svakoj promjeni filtera.

14.3 Pregled ključnih funkcionalnosti interfejsa

Upravljanje aplikacijom vrši se putem bočne trake (*Sidebar*) kroz nekoliko analitičkih cjelina:

- **Kontrolni filteri (*Side Panel*):** Omogućavaju pojedinačni izbor države (*Country Selector*) radi označavanja njenog položaja na globalnim prikazima, kao i filtriranje po geografskim regionima (*Regional Indicator Filter*).
- **Sintetičke KPI kartice:** Dinamički prikazuju sirove vrijednosti za odabranu državu (Happiness Score, Logged GDP per capita, Social Support, Healthy Life Expectancy, Freedom, Generosity, Perceptions of corruption).
- **Scatter Plot BDP vs. Sreća:** Prikazuje nelinearnu/logaritamsku vezu između BDP-a i indeksa sreće za sve zemlje, uz vizuelno isticanje odabrane države u odnosu na globalni prosjek.
- **Rang liste (Top 10 / Bottom 10):** Horizontalni stubičasti dijagrami (*Bar charts*) koji trenutno identifikuju globalne lidere u blagostanju (npr. Finska, Danska) i najugroženije nacije (npr. Avganistan, Liban).
- **Heatmap Pearsonovih korelacija:** Interaktivna toplotna mapa koja rekreira matricu korelacije svih šest faktora i omogućava brzu provjeru jačine povezanosti na licu mjesta (npr. $r = 0.835$ za Social support).

REZULTATI I KOMPARATIVNA ANALIZA MODELA

Nakon faze obuke, optimizacije i evaluacije nad nepristrasnim testnim skupom (izdvojenih 20% zemalja), dobili smo kvantitativne pokazatelje performansi za sva tri posmatrana algoritma mašinskog učenja.

15.1 Zbirna tabela evaluacije modela

U tabeli ispod prikazani su zvanični rezultati metričkih pokazatelja nad testnim skupom: koeficijent determinacije (R^2), srednja apsolutna greška (MAE) i korijen srednje kvadratne greške (RMSE).

Algoritam / Model	Test R2 Score	Test MAE	Test RMSE	Status i Ocjena performansi
Linear Regression	0.780	0.406	0.512	Pobjednički model (Najbolja generalizacija)
XGBoost Regressor	0.745	0.435	0.551	Stabilan ansambl (Dobre performanse uz regularizaciju)
Random Forest Regressor	0.728	0.452	0.574	Zadovoljavajući (Prisutan blagi overfitting)

Napomena: Vrijednosti prikazane u tabeli predstavljaju očitane parametre iz evaluacijskog izvještaja projektnog koda.

15.2 Dubinska interpretacija i analitički uvidi

Rezultati evaluacije donose nekoliko ključnih uvidnih tačaka od presudne važnosti za razumijevanje primjene metodologije mašinskog učenja na socio-ekonomskim podacima:

- **Magnituda greške u realnom kontekstu (MAE = 0.406):** Za pobjednički model, ostvarena srednja apsolutna greška iznosi 0.406 poena. S obzirom na to da se raspon ocjena sreće u WHR2023 skupu kreće od 1.85 do 7.80, odstupanje od svega ≈ 0.4 poena predstavlja izuzetno visoku prediktivnu preciznost.
- **Objašnjeni varijabilitet ($R^2 = 0.780$):** Koeficijent determinacije od 0.780 ukazuje na to da kombinacija šest odabranih faktora uspješno objašnjava čak 78% ukupnog varijabiliteta u nacionalnoj sreći. Preostalih 22% varijanse otpada na unutrašnje specifičnosti država, kulturološke faktore i metodološki šum pri anketiranju.
- **Paradoks složenosti (Zašto jednostavan model nadmašuje ansamble):**
 - **Ograničena dimenzionalnost uzorka ($N = 137$):** Kompleksni ansambl bazirani na stablima odluke zahtijevaju znatno veći broj opservacija. Na ovako malom skupu podataka, Random Forest i XGBoost naginju tome da "zapamte" specifičnosti trening skupa, što dovodi do sklonsoti preprilagođavanju (*overfitting*) i pada generalizacije na testnom skupu.
 - **Priroda domena (Linearnost socio-ekonomskih odnosa):** Nakon logaritmovanja BDP-a (Logged GDP per capita), odnosi između glavnih prediktora i ocjene sreće postaju pretežno linearni. U takvim uslovima, linearna hiper-ravan pruža matematički optimalno uklapanje.
 - **Regularizacijski efekat OLS-a:** Klasična linearna regresija primijenjena na mali broj varijabli ($k = 6$) djeluje kao prirodni regularizator koji sprječava model da uči šum iz podataka.

DISKUSIJA I KRITIČKA REFLEKSIJA

Nakon prezentovanja empirijskih rezultata korelacione analize, regresionih modela i klasterizacije, ova sekcija sintetizuje ključne spoznaje i daje direktne odgovore na fundamentalna istraživačka pitanja.

16.1 Da li su najbogatije zemlje ujedno i najsretnije?

Osnovno pitanje od kojeg polazi većina ekonomskih analiza blagostanja glasi: *da li je ekonomski rast, izražen kroz BDP po glavi stanovnika, dovoljan uslov za maksimizaciju ljudske sreće?*

Na osnovu svih sprovedenih analiza, odgovor glasi: **NE NUŽNO.**

- 1. **BDP je važan, ali ne i dovoljan:** Korelaciona analiza ($r = 0.784$) i univarijantni model ($R^2 = 0.615$) potvrđuju da bogatije zemlje u pravilu bilježe više ocjene sreće.
- 2. **Socijalni kapital nadmašuje ekonomski:** Socijalna podrška (Social support) ostvaruje jaču povezanost sa srećom ($r = 0.835$) i zauzima ubedljivo prvo mjesto po važnosti unutar modela mašinskog učenja (Feature Importance $\approx 42\%$). Zemlja može imati izuzetno visok BDP, ali ukoliko joj nedostaju društvena kohezija i osjećaj sigurnosti u zajednici, opšta ocjena blagostanja opada.
- 3. **Sinergija šest stubova:** Pobjednički model koristi kombinaciju svih šest faktora i time podiže objašnjeni varijabilitet sa 61.% na 78.0%, što nedvosmisleno dokazuje da je sreća multidimenzionalan fenomen.

16.2 Anomalije u podacima: Nekongruentnost BDP-a i Sreće

Da bogatstvo ne garantuje sreću direktno, najbolje pokazuju primjeri konkretnih država iz WHR2023 skupa:

Tabela 16.1: Primjeri odstupanja između nivoa BDP-a i indeksa sreće

Država	Logged GDP per capita	Happiness score	Analitički uvid / Raskorak
Hong Kong S.A.R.	10.966 (U samom vrhu)	5.308 (Ispod medijane)	Izuzetno visok BDP, ali niža sreća usljed gustine, stresa i društveno-političkih izazova
Kosovo	9.359 (Skroman BDP)	6.368 (Visoka sreća)	Skromnija ekonomija, ali visoka ocjena sreće zahvaljujući jakim porodičnim i društvenim vezama

Nicaragua	8.618 (Nizak BDP)	6.259 (Visoka sreća)	Latinskoamerički fenomen – izražena socijalna bliskost nadoknađuje ekonomski deficit
-----------	-------------------	----------------------	--

16.3 Ograničenje poprečnog presjeka (*Cross-Sectional*) i Easterlinov paradoks

U akademskoj analizi rada od presudne je važnosti pokazati razumijevanje metodoloških dometa i ograničenja sprovedenog istraživanja:

Metodološka napomena: Ovaj projekat **NE DOKAZUJE** Easterlinov paradoks u njegovom izvornom, vremenskom (*longitudinalnom*) smislu, već analizira poprečni presjek (*cross-sectional data*) za jednu tačku u vremenu (godinu 2023).

- **Cross-Sectional uvid (Ovaj projekat):** U 2023. godini, zemlje sa višim BDP-om u prosjeku imaju viši Happiness score od zemalja sa niskim BDP-om (poređenje između različitih država u istoj tački vremena).
- **Easterlinov paradoks (Longitudinalni uvid):** Richard Easterlin (1974) je uočio da vremenski rast BDP-a unutar jedne te iste zemlje tokom decenija **NE DONOSI** automatski i trajan rast prosječne sreće njenog stanovništva (zbog psihološke adaptacije i koncepta "hedoničke trake").
- **Zaključak:** Projekat potvrđuje postojanje snažne logaritamske povezanosti BDP-a i sreće u prostoru (među zemljama), ali bi za dokazivanje Easterlinovog paradoksa bilo neophodno analizirati vremenske serije (*panel* podatke) kroz više decenija.

16.4 Implikacije za donošenje javnih politika (*Policy Implications*)

Nalazi ove diskusije nose jasne preporuke za kreatore ekonomskih i socijalnih politika:

- **Pomjeranje težišta sa BDP-a na šire indekse blagostanja:** Vlade ne bi trebale mjeriti uspješnost društva isključivo rastom BDP-a, već uvođenjem i praćenjem nacionalnih indeksa sreće i blagostanja.
- **Ulaganje u socijalni kapital i zdravstvo:** S obzirom na to da socijalna podrška ima veću težinu od samog BDP-a, javne politike usmjerene na smanjenje usamljenosti, jačanje lokalnih zajednica, borbu protiv korupcije i preventivno zdravstvo daju znatno veće "prinose" u vidu opšteg zadovoljstva građana.

OGRANIČENJA ISTRAŽIVANJA

Iako primijenjeni metodološki okvir i modeli mašinskog učenja pružaju visoku prediktivnu preciznost ($R^2 = 0.780$) i duboke analitičke uvide, objektivno vrednovanje postignutih rezultata

zahtijeva jasno mapiranje usvojenih ograničenja. Ova ograničenja proističu iz prirode samih podataka, primijenjenog eksperimentalnog dizajna i kompleksnosti posmatranog fenomena.

17.1 Podatkovni i uzorački okviri

1. **Restriktivan obim uzorka (N = 137 zemalja):** Skup podataka WHR2023 obuhvata 137 država i teritorija sa kompletnim podacima. U kontekstu mašinskog učenja, ovaj uzorak spada u kategoriju malih skupova podataka (*Small Datasets*), što onemogućava primjenu dubokih mreža (*Deep Learning*) ili izrazito kompleksnih ansambl algoritama (poput dubokih Random Forest i XGBoost stabala) bez velikog rizika od preprilagođavanja (*overfitting*).
2. **Temporalni obuhvat (Jedna kalendarska godina):** Analiza je fokusirana isključivo na podatke iz izvještaja za 2023. godinu. Izostavljanje višegodišnjih vremenskih serija onemogućava praćenje dinamike, trendova oporavka nakon globalnih kriza (poput pandemije COVID-19 ili inflatornih šokova) i evolucije blagostanja kroz vrijeme.
3. **Neuključivanje eksternih baza Svjetske banke:** Iako je u sklopu preliminarne analize razmatrano spajanje (*merge*) sa bazama podataka Svjetske banke (npr. stope nezaposlenosti, GINI koeficijent imovinske nejednakosti, inflacija, stope urbanizacije), finalni model je zadržan isključivo na izvornoj WHR2023 strukturi radi očuvanja metodološke konzistentnosti i izbjegavanja problema sa nedostajućim vrijednostima (*Missing Data*).

17.2 Metodološka i uzročno-posljedična ograničenja

4. **Statistički dizajn poprečnog presjeka (*Cross-Sectional Analysis*):** Istraživanje se oslanja na podatke prikupljene u jednoj vremenskoj tački, što omogućava analizu razlika između zemalja, ali ne i praćenje promjena unutar jedne te iste zemlje kroz duži vremenski period.
5. **Nemogućnost dokazivanja kauzalnosti (*Korelacija ≠ Kauzalnost*):** Primijenjeni regresioni modeli i analize korelacije identifikuju statističku povezanost i prediktivnu moć, ali ne dokazuju uzročno-posljedične veze. Nije moguće sa apsolutnom sigurnošću tvrditi da povećanje socijalne podrške direktno uzrokuje viši stepen sreće, ili da sretnija društva organski razvijaju snažnije mehanizme međusobne podrške i povjerenja (problem reverzne uzročnosti).

17.3 Konceptualna ograničenja i neobuhvaćeni faktori

6. **Sreća kao kompleksan i subjektivan konstrukt:** Zavisna varijabla Happiness score zasnovana je na Cantrilovoj ljestvici (*Cantril Ladder*), koja mjeri subjektivni doživljaj blagostanja pojedinca (skala 0–10). Subjektivne procjene su podložne kulturološkim pristrasnostima (*Cultural Bias*) - u pojedinim kulturama postoji tendencija davanja umjerenijih odgovora, dok su u drugima prisutni izraženi ekstremi.
7. **Izostavljeni socio-ekonomski i ekološki faktori:** Finalni model obuhvata šest standardnih WHR faktora, izostavljajući varijable poput:
 - Imovinske nejednakosti (GINI indeks),

- Klimatskih uslova i ekološkog kvaliteta (zagađenost vazduha, pristup zelenim površinama),
- Geopolitičke stabilnosti i stope kriminala,
- Kulturoloških i religijskih specifičnosti regionalnih zajednica.

17.4 Sintetički pregled ograničenja

Tabela 17.1: *Pregled dimenzija ograničenja i njihovih metodoloških implikacija*

Dimenzija ograničenja	Karakteristika u projektu	Metodološka implikacija
Veličina uzorka	N = 137 zemalja	Favorizuje jednostavnije modele (Linearna regresija nadmašila kompleksne ansamble)
Vremenski okvir	Jedna godina (2023)	Nemogućnost analize longitudinalnih trendova i dinamike
Uzočnost	Cross-sectional matrica	Zadržavanje na nivoima korelacije i predikcije, bez izvođenja kauzalnih pretpostavki
Podatkovni opseg	Bez World Bank baze	Očuvana čistota baze, ali izostavljeni indikatori poput GINI indeksa I nezaposlenosti
Zavisna varijabla	Subjektivna anketna	Moguć uticaj kulturoloških specifičnosti na normiranje odgovora

Zaključak: Svjesnost o navedenim ograničenjima ne umanjuje naučnu i praktičnu vrijednost projekta, već precizno definiše granice u kojima su izvedeni zaključci važeći, pružajući istovremeno jasne smjernice i temelje za buduća proširenja istraživanja.

ZAKLJUČAK I ZAVRŠNA RAZMATRANJA

Sprovedeno istraživanje imalo je za cilj sveobuhvatnu analizu socio-ekonomskih determinanti koje oblikuju globalni indeks sreće (Happiness Score), primjenom savremenih metoda obrade podataka, eksploratorne analize (EDA), deskriptivne statistike te tehnika nadgledanog (*Supervised*) i nenadgledanog (*Unsupervised*) mašinskog učenja nad podacima iz izvještaja *World Happiness Report 2023*.

18.1 Sublimacija ključnih nalaza

Kroz razvijeni metodološki cjevovod ostvareni su sljedeći naučni i praktični rezultati:

- Prediktivna snaga socio-ekonomskih faktora:** Pobjednički model mašinskog učenja (Linearna regresija) ostvario je visoki koeficijent determinacije ($R^2 = 0.780$) nad testnim skupom, uz prosječnu apsolutnu grešku od svega $MAE = 0.406$ poena. Ovi rezultati potvrđuju da je čak 78% varijabiliteta u nacionalnoj sreći objašnjivo pomoću šest osnovnih WHR faktora.
- Superiornost jednostavnijeg modela u uslovima malog uzorka:** Metodološko poređenje pokazalo je da je Linearna regresija nadmašila složene ansambl algoritme (XGBoost sa $R^2 = 0.745$ i Random Forest sa $R^2 = 0.728$). Na ograničenom uzorku od $N = 137$ zemalja, jednostavna hiper-ravan pruža optimalnu generalizaciju bez rizika od prilagođavanja (*overfitting*).
- Prirodna struktura globalne stratifikacije:** Primjenom K-Means algoritma nenadgledanog učenja ($K=3$, verifikovano *Elbow* i *Silhouette* analizom), zemlje svijeta su se autonomno grupisale u tri jasne makro-kategorije (zemlje niskog razvoja, tranzicijski pojas i visoko razvijene države). Profili ovih klastera u potpunosti odražavaju hijerarhiju indeksa sreće, što dokazuje da je blagostanje direktna manifestacija dubinskih socio-ekonomskih struktura.

18.2 Završni odgovori na hipoteze i istraživačka pitanja

Tabela 18.1: Sintetički pregled validacije hipoteza i istraživačkih pitanja

Hipoteza / Istraživačko pitanje	Empirijski status	Ključni dokaz iz projekta
H_1: BDP po glavi stanovnika ima snažan pozitivan uticaj na sreću.	POTVRĐENO	Korelacija $r = 0.784$; univarijantni $R^2 = 0.615$.
H_2: Socijalni kapital (Social support) ima veći značaj od BDP-a.	POTVRĐENO	Korelacija $r = 0.835$; Feature Importance $\approx 42\%$.

H_3: Kompletni socio-ekonomski profil objašnjava većinu varijanse sreće.	POTVRĐENO	Multivarijantna Linearna regresija ostvaruje $R^2 = 0.780$.
Glavno pitanje: <i>Da li su najbogatije zemlje ujedno i najsretnije?</i>	NE NUŽNO	BDP je neophodan temelj, ali bez socijalne podrške i sloboda nije dovoljan.

Rezultati projekta nedvosmisleno pokazuju da ekonomsko bogatstvo predstavlja značajan faktor povezan sa nacionalnom srećom, ali ne predstavlja dovoljan uslov za njeno potpuno objašnjenje. Iako je Logged GDP per capita ostvario snažnu pozitivnu povezanost sa Happiness score-om, Social support (socijalna podrška i društvena kohezija) pokazao je još izraženiju povezanost i veći ponder unutar prediktivnih modela mašinskog učenja.

Ljudsko blagostanje je kompleksan, multidimenzionalan fenomen. Ekonomski rast stvara neophodnu materijalnu osnovu i egzistencijalnu sigurnost, ali tek u kombinaciji sa snažnom socijalnom mrežom, visokim očekivanim životnim vijekom, ličnim slobodama i društvenim povjerenjem (niskom korupcijom) rezultira vrhunskim kvalitetom života.

Zbog toga, glavna poruka i zaključak ove analize glasi: **Najbogatije zemlje nisu nužno i najsretnije zemlje.**