

Univerzitet “Džemal Bijedić” u Mostaru  
Fakultet informacijskih tehnologija



Predmet: Mašinsko učenje

**Money vs Happiness**

Dokumentacija projekta

Profesor :

Dr. Sc. Mirela Mabić

Student:

Lana Mustafić, IB210240

Akadska 2025/2026. godina

Mostar, septembar 2026.

CILJ MODELA

Osnovni cilj je identifikovati i matematički modelirati odnos između šest navedenih faktora i nivoa sreće, kako bi se odgovorilo na ključno istraživačko pitanje:

*Da li se nivo sreće neke države može pouzdano predvidjeti na osnovu njenih ekonomskih i društvenih parametara, te da li je sam BDP dovoljan za njegovo objašnjenje?*

1.2 Hipoteze rada

- **H\_1:** Postoji jaka i statistički značajna pozitivna povezanost između BDP-a po glavi stanovnika (Logged GDP per capita) i ocjene sreće (Happiness score).
- **H\_2:** Sam BDP nije dovoljan za preciznu predikciju sreće - socijalni, zdravstveni i institucionalni faktori imaju ključnu prediktivnu ulogu.

OPERACIONALIZACIJA I METRIKA

| Istraživački element       | Varijabla / Metoda                                            | Indikator / Metrika                                  |
|----------------------------|---------------------------------------------------------------|------------------------------------------------------|
| Ekonomsko bogatstvo        | Logged GDP per capita                                         | Pearsonov koeficijent (r), R <sup>2</sup> score      |
| Nacionalna sreća (Cilj)    | Happiness score                                               | Kontinuirana skala (WHR 2023)                        |
| Socijalni i ostali faktori | Social support, Freedom, Healthy life, Corruption, Generosity | Feature Importance, koeficijenti regresije           |
| Procjena modela            | Linearna regresija, Random Forest, XGBoost                    | 5-fold CV, Test metrics (R <sup>2</sup> , MAE, RMSE) |

OPIS SKUPA PODATAKA

Analiza i modeliranje se zasnivaju na zvaničnom skupu podataka iz **World Happiness Report 2023**. Osnovne informacije o skupu podataka prikazane su u Tabeli 3.1, dok su ulazne karakteristike opisane u Tabeli 3.2.

**Tabela 3.1:** Osnovne informacije o skupu podataka

| Stavka                     | Vrijednost                               |
|----------------------------|------------------------------------------|
| Izvor                      | World Happiness Report 2023              |
| Godina                     | 2023                                     |
| Broj zemalja (uzorak)      | 137                                      |
| Broj ML karakteristika (X) | 6 (sve numeričke)                        |
| Ciljna varijabla (y)       | Happiness score (kontinuirana numerička) |

**Tabela 3.2:** Pregled ulaznih karakteristika modela

| Karakteristika               | Tip       | Uloga                  |
|------------------------------|-----------|------------------------|
| Logged GDP per capita        | Numerička | Ekonomski factor       |
| Social support               | Numerička | Socijalni faktor       |
| Healthy life expectancy      | Numerička | Zdravstveni faktor     |
| Freedom to make life choices | Numerička | Institucionalni faktor |
| Generosity                   | Numerička | Socijalni faktor       |
| Perceptions of corruption    | Numerička | Institucionalni faktor |

## IZVOR PODATAKA

### 4.1 Primarni izvor podataka - WHR 2023

Primarni i jedini izvor podataka korišten u ovom projektu je **World Happiness Report 2023** koji objavljuje UN SDSN u saradnji sa Gallup World Poll-om.

**Tabela 4.1:** *Metapodaci primarnog izvora*

| Metadatak              | Opis                                                              |
|------------------------|-------------------------------------------------------------------|
| Naziv izvora           | World Happiness Report 2023                                       |
| Izdavač                | SDSN / Gallup World Poll                                          |
| Godina izdanja         | 2023.                                                             |
| Putanja u repozitoriju | data/WHR2023.csv                                                  |
| Obim skupa             | 137 zemalja x 21 kolona (sirovi CSV)                              |
| Uloga u projektu       | Izvor za ciljnu varijablu (y) i svih 6 ulaznih karakteristika (x) |

**Zašto baš WHR 2023?** Ova baza već spaja subjektivni osjećaj sreće sa zvaničnim ekonomskim podacima. Svi podaci su unaprijed sređeni i međunarodno uporedivi, pa nismo morali ručno peglati nazive država ili gubiti vrijeme na usklađivanje različitih godina.

## 4.2 Nekorišteni pomoćni podaci

U direktoriju data/raw/ nalaze se i dodatne datoteke Svjetske banke (npr. inflacija, nezaposlenost, populacija, upotreba interneta). Iako inicijalno preuzete, **ove datoteke nisu integrisane u konačni ML model** iz sljedećih razloga:

1. **Izbjegavanje šuma i redundantnosti:** WHR 2023 već sadrži standardizovane i logaritmovane podatke pripremljene od strane stručnjaka UN-a.
2. **Sprečavanje gubitka uzorka:** Spajanje vanjskih izvora dovelo bi do gubitka redova (zemalja) usljed nedostajućih podataka.
3. **Integritet evaluacije:** Zadržavanje čistog skupa od 137 zemalja obezbjeđuje potpunu konzistentnost pri unakrsnoj validaciji.

## 4.3 Pregled korištenih i nekorištenih varijabli

**Tabela 4.2:** *Koncepcijski pregled varijabli u radu*

| Koncept / Varijabla                  | Teorijsko značenje                   | Status u ML modelu                      |
|--------------------------------------|--------------------------------------|-----------------------------------------|
| <b>Logged GDP per capita</b>         | Logaritam BDP-a po stanovniku (PPP)  | <b>KORIŠTENO (X_1)</b>                  |
| <b>Social support</b>                | Percepcija dostupnosti podrške       | <b>KORIŠTENO (X_2)</b>                  |
| <b>Healthy life exptectancy</b>      | Očekivani broj godina zdravog života | <b>KORIŠTENO (X_3)</b>                  |
| <b>Freedom to make choices</b>       | Percepcija lične slobode             | <b>KORIŠTENO (X_4)</b>                  |
| <b>Generosity</b>                    | Mjera velikodušnosti                 | <b>KORIŠTENO (X_5)</b>                  |
| <b>Perceptions of corruption</b>     | Percepcija korupcije                 | <b>KORIŠTENO (X_6)</b>                  |
| <b>Happiness score</b>               | Subjektivna procjena života          | <b>KORIŠTENO (Cilj - y)</b>             |
| <b>Unemployment / Inflation</b>      | Makroekonomski indikatori            | <b>Nije korišteno (samo u data/raw)</b> |
| <b>Internet usage / Population</b>   | Tehnologija I demografija            | <b>Nije korišteno (samo u data/raw)</b> |
| <b>Human Development Index (HDI)</b> | Kompozitni indeks razvoja UN-a       | <b>Nije korišteno</b>                   |

## UCITAVANJE PODATAKA

Prva faza realizacije obuhvata učitavanje, validaciju i provjeru strukture skupa podataka primjenom biblioteke pandas.

### 5.1 Arhitektura učitavanja (src/data\_loader.py)

Radi postizanja modularnosti i sprječavanja grešaka u putanjama, učitavanje je inkapsulirano unutar centralizovanog modula src/data\_loader.py.

```

from pathlib import Path
import pandas as pd

DEFAULT_DATA_PATH = Path(__file__).resolve().parents[1] / "data" / "WHR2023.csv"

def load_raw_data(path: Path | str | None = None) -> pd.DataFrame:
    """Učitava sirove WHR 2023 podatke sa zadate putanje."""
    data_path = Path(path) if path else DEFAULT_DATA_PATH
    if not data_path.exists():
        raise FileNotFoundError(f"Dataset nije pronađen na putanji: {data_path}")
    return pd.read_csv(data_path)

```

## 5.2 Razdvajanje modela: ML vs. EDA scenarij

U projektu su definisana dva odvojena puta učitavanja podataka u zavisnosti od njihove namjene:

- **ML put (load\_for\_modeling()):** Podaci se učitavaju bez ručne popune nedostajućih vrijednosti. Nedostajuće vrijednosti se namjerno zadržavaju kako bi ih komponenta SimpleImputer obradila unutar Scikit-Learn (*Pipeline*) isključivo na trening skupu, čime se u potpunosti sprječava **curenje podataka (data leakage)**.
- 
- **EDA i Dashboard put (load\_and\_prepare()):** Podaci se učitavaju uz globalnu imputaciju srednjom vrijednošću (*mean*), što je namijenjeno za eksploratornu analizu u Jupyter notebooku i interaktivni prikaz u Streamlit aplikaciji.
- 

## 5.3 Inicijalna verifikacija strukture

Nakon učitavanja izvršene su automatske provjere strukture i integriteta skupa podataka.

**Tabela 5.1:** Rezultati inicijalne provjere skupa podataka

| Pandas metoda / Atributa | Svrha i rezultat na WHR2023.csv                           |
|--------------------------|-----------------------------------------------------------|
| df.shape                 | Dimenzionalnost matrica: 137 redova (zemalja) i 21 kolona |
| df.head ()               | Vizuelna provjera ispravnosti zaglavlja i separatora      |
| df.info ()               | Prikaz tipova podataka (float64, object) i popunjenosti   |

|                               |                                                                              |
|-------------------------------|------------------------------------------------------------------------------|
| df.isna ().sum ()             | Detekcija nedostajućih vrijednosti (utvrđen 1 NaN u Healthy life expectancy) |
| Df[“Country name”].nunique () | Potvrda jedinstvenosti: 137 jedinstvenih zemalja (bez duplikata)             |

## ČIŠĆENJE I PRETPROCESIRANJE PODATAKA

Baza je izuzetno dobro popunjena - od ukupno 137 zemalja, zabilježena je samo jedna nedostajuća vrijednost (NaN) i to u koloni Healthy life expectancy (manje od 0.73% uzorka).

Nedostajući podatak je popunjen srednjom vrijednošću (*Mean Imputation*), uz pažljivo odvojen pristup za ML i analitiku:

1. **Za ML modele (Sprečavanje *Data Leakage*-a):** Imputacija se radi unutar scikit-learn biblioteke koristeći SimpleImputer(strategy="mean"). Srednja vrijednost se računa **isključivo na trening skupu** (fit), a zatim samo primjenjuje na testni skup (transform).
2. **Za EDA i Dashboard:** Funkcija handle\_missing\_values() popunjava nedostajuću vrijednost nad cijelim skupom odjednom, kako bi se grafikoni i tabele u izveštajima i na *dashboardu* mogli nesmetano prikazati.

```
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.linear_model import LinearRegression

# Standardni ML Pipeline u projektu
model_pipeline = Pipeline([
    ("imputer", SimpleImputer(strategy="mean")),
    ("model", LinearRegression())
])
```

### 6.2 Selekcija karakteristika (*Feature Selection*)

Od ukupno 21 kolone u sirovom CSV-u, funkcija prepare\_features() vrši redukciju na 10 ključnih varijabli.

Pomoćne kolone poput Explained by: ... su uklonjene kako bi se izbjeglo **cirkularno rezonovanje**, jer predstavljaju direktnu dekompoziciju ocjene sreće.

**Tabela 8.1:** *Struktura odabranih kolona u projektu*

| Kategorija kolona                | Nazivi kolona                                                                                                                                 | Uloga u analizi                                                     |
|----------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------|
| <b>Ciljna varijabla (y)</b>      | Happiness score                                                                                                                               | Kontinuirani izlaz koji model predviđa                              |
| <b>Ulazne karakteristike (X)</b> | Logged GDP per capita<br>Social support<br>Healthy life expectancy<br>Freedom to make life choices<br>Generosity<br>Perceptions of corruption | Skup od 6 socio-ekonomskih prediktora                               |
| <b>Metapodaci</b>                | Country name, Regional indicator, iso alpha                                                                                                   | Identifikatori za filtriranje i vizuelizaciju (ne ulaze u ML model) |

### 6.3 Validacija i finalne matrice (X i y)

Prije slanja u modele, sprovedene su sljedeće provjere:

- **Verifikacija tipova:** Svih 6 prediktora i ciljna varijabla verifikovani su kao float64 tipovi.
- **Mapiranje i fleksibilnost:** Kolona Ladder score se automatski preimenuje u Happiness score radi kompatibilnosti sa starijim verzijama skupa.
- **Priprema matrica:** Podaci se razdvajaju u dvodimenzionalnu matricu osobina X dimenzija (137, 6) i vektor ciljne varijable y dužine 137.

```
# Finalni oblik matrica spremnih za ML pipeline
X = df[[
    'Logged GDP per capita',
    'Social support',
    'Healthy life expectancy',
    'Freedom to make life choices',
    'Generosity',
    'Perceptions of corruption'
]] # Matrica dimenzija (137, 6), tip: float64

y = df['Happiness score'] # Vektor dimenzije (137,), tip: float64
```

## EKSPLOATORNA ANALIZA PODATAKA (EDA)

Eksploratorna analiza (EDA) otkriva strukturu, raspodjele, multikolinearnost i klastere unutar skupa podataka WHR2023.csv. Analiza je mapirana na 8 ključnih slika (*Figure 1 – 8*).

### 7.1 Distribucija ciljne varijable (Figure 1)

Analiza distribucije zavisne varijable Happiness score (skala 0–10) pokazuje:

- **Simetrična distribucija:** Zvonolik oblik sa srednjom vrijednošću  $\approx 5.53$  i medijanom  $\approx 5.68$ .
- **Raspon:** Najniža ocjena je 1.85 (Afganistan), a najviša 7.80 (Finska).
- **Implikacija za ML:** Odsustvo ekstremnog zakrivljenja omogućava direktnu primjenu linearne regresije i RMSE funkcije gubitka bez potrebe za logaritamskom transformacijom ciljne varijable y.

### 7.2 Korespondencija i multikolinearnost (Figure 2 & Figure 3)

Pearsonova analiza korelacije (r) i Boxplot analiza identifikuju ključne prediktore i raspodjele:

**Tabela 7.1:** Pearsonov koeficijent korelacije u odnosu na Happiness score

| Karakteristika (X)    | Pearsonov r    | Zapažanje i struktura                                       |
|-----------------------|----------------|-------------------------------------------------------------|
| Logged GDP per capita | $\approx 0.78$ | Najsnažniji pozitivni predictor sreće                       |
| Social support        | $\approx 0.75$ | Snažab uticaj socijalne mreže; visoka zbijenost ( $>0.80$ ) |

|                                     |                 |                                                    |
|-------------------------------------|-----------------|----------------------------------------------------|
| <b>Healthy life expectancy</b>      | $\approx 0.74$  | Visoka korelacija sa BDP-on ( $r > 0.80$ )         |
| <b>Freedom to make life choices</b> | $\approx 0.60$  | Umjereno snažan institucionalni predictor          |
| <b>Perceptions of corruption</b>    | $\approx -0.47$ | Negativna korelacija; prisutan veći broj autlajera |
| <b>Generosity</b>                   | $\approx 0.04$  | Slaba linearna povezanost, izraženija asimetrija   |

**Metodološka napomena:** BDP i očekivani životni vek su u jakoj korelaciji ( $r > 0.80$ ). To znači da imamo problem **multikolinearnosti**, pa je skroz opravdano što koristimo regularizaciju (Ridge/Lasso) i modele bazirane na stablima odluke.

### 7.3 Nelinearnost i Easterlinov paradoks (Slika 4)

- **Grafik raspršenosti (Scatter plot)** odnosa BDP-a i sreće lepo prikazuje princip *opadajućih prinosa*: skok iz niskog u srednji BDP donosi ogroman porast u sreći, dok se na visokim nivoima bogatstva taj efekat "popeglat" i stane (saturacija).
- Pošto je BDP u bazi već **logaritmovan** (Logged GDP per capita), ovaj odnos je uspešno linearizovan kako bi regresioni modeli mogli normalno da rade sa njim.

### 7.4 Evaluacija modela i važnost osobina (Slika 5 i Slika 6)

- **Performanse (Slika 5):** Obična i Ridge linearna regresija daju najbolje rezultate na testnom skupu ( $R^2 \approx 0.75 - 0.77$ ). Kompleksnija stabla lagano preprilagođavaju (*overfitting*) jer nam je uzorak prilično mali ( $N=137$ ).
- **Važnost varijabli (Slika 6):** Izlaz iz Random Forest-a i XGBoost-a jasno pokazuje da priči dominiraju dve stvari: BDP po glavi stanovnika (nosi preko 40% uticaja) i socijalna podrška (Social support, sa oko 25%).

### 7.5 Segmentacija zemalja — K-Means klasterovanje (Slika 7 i Slika 8)

- **Bira se broj klastera (Slika 7):** *Elbow* metoda (prelom na WCSS krivi) i *Silhouette* score nedvosmisleno pokazuju da je najbolje podeliti podatke na **K=3** klastera.
- **Prostorna segmentacija (Slika 8):**
  - **Klaster 0 (Nizak razvoj):** Države sa niskim BDP-om i slabom ocenom sreće (uglavnom subsaharska Afrika i krizna područja).
  - **Klaster 1 (Srednji razvoj):** Zemlje u razvoju (Latinska Amerika, Jugoistočna Evropa, deo Azije).
  - **Klaster 2 (Visok razvoj):** Razvijene ekonomije (Nordijske zemlje, Zapadna Evropa, Severna Amerika) sa visokim BDP-om i jakom socijalnom mrežom.

## ANALIZA KORELACIJE

Linearne povezanosti između ulaznih varijabli (X) i cilja (y) kvantifikovane su **Pearsonovim koeficijentom korelacije (r)**.

### 8.1 Empirijski rezultati

**Tabela 8.1:** *Pearsonov koeficijent korelacije u odnosu na Happiness score*

| Socio-ekonomski faktor (X)          | Pearsonov koeficijent (r) | Smjer i jačina povezanosti         |
|-------------------------------------|---------------------------|------------------------------------|
| <b>Social support</b>               | +0.835                    | Izuzetno jaka pozitivna korelacija |
| <b>Logged GDP per capita</b>        | +0.784                    | Snažna pozitivna korelacija        |
| <b>Healthy life expectancy</b>      | +0.746                    | Snažna pozitivna korelacija        |
| <b>Freedom to make life choices</b> | +0.663                    | Umjereno jaka pozitivna korelacija |
| <b>Generosity</b>                   | +0.044                    | Zanemarljiva / Nulta korelacija    |
| <b>Perceptions of corruption</b>    | -0.472                    | Umjereno jaka negativna korelacija |

### 8.2 Šta nam govore ovi faktori?

1. **Social support (r = 0.835):** Ubjedljivo najjači pojedinačni faktor. Pokazuje da nam je osjećaj da se imamo na koga osloniti u životu važniji za sreću čak i od samog novca.
2. **Logged GDP per capita (r = 0.784):** Glavni materijalni oslonac blagostanja. Ovo direktno potvrđuje našu prvu hipotezu (H<sub>1</sub>) - ekonomski razvoj jeste ključan temelj.
3. **Healthy life expectancy (r = 0.746):** Zdravlje i očekivani životni vijek u stopu prate to koliko su ljudi zadovoljni životom.
4. **Freedom to make choices (r = 0.663):** Lična sloboda i mogućnost izbora predstavljaju jako važan nematerijalni faktor.
5. **Perceptions of corruption (r = -0.472):** Očekivano negativna korelacija — što je percepcija korupcije veća, povjerenje opada, a s njim i opšta sreća.
6. **Generosity (r = 0.044):** Ovdje praktično nema nikakve linearne veze. To koliko su ljudi u prosjeku filantropski nastrojeni na nivou države ne utiče direktno na opštu ocjenu sreće.

### 8.3 Važno upozorenje: Korelacija nije isto što i kauzalnost!

To što neki faktori imaju visoku korelaciju sa srećom ne znači automatski da oni direktno uzrokuju sreću. Za to postoje tri glavna razloga:

- **Skrivene varijable (Confounding Variables):** Bogatije zemlje obično „u paketu“ imaju i bolje zdravlje, jaču vladavinu prava i stabilnije institucije, pa je teško razdvojiti šta tačno utiče na šta.
- **Jedna tačka u vremenu (Cross-section):** Podaci su samo iz 2023. godine. Prikazuju trenutno stanje među zemljama, a ne kako se situacija mijenja kroz vrijeme unutar jedne države.
- **Obrnuta uzročnost (Reversed Causality):** Uzročni smjer može biti obrnut — možda sretniji i zdraviji ljudi prave jaču ekonomiju, a ne samo obrnuto.

Zaključak: Korelacija nam daje odličnu osnovu za prave prediktivne ML modele, ali je ne smijemo tumačiti kao slijepi dokaz uzroka i posljedice.

### 8.4 Korelacije među prediktorima (provjera redundantnosti)

Analiza u poglavljima 8.1–8.3 kvantifikuje povezanost svakog socio-ekonomskog faktora sa ciljnom varijablom Happiness score. To, međutim, ne odgovara na drugo, metodološki jednako važno pitanje: jesu li neki od šest prediktora međusobno toliko slični da jedan od njih treba ukloniti iz modela? Takva sličnost naziva se multikolinearnost (redundantnost karakteristika). Ako dva faktora nose gotovo istu informaciju, linearna regresija može dati nestabilne koeficijente, a interpretacija „šta tačno utiče na sreću“ postaje zamagljena.


U tu svrhu izračunata je Pearsonova korelaciona matrica isključivo među šest ulaznih karakteristika (cilj  $y$  nije uključen), te dodatni dijagnostički pokazatelj VIF (Variance Inflation Factor). Implementacija je u modulu `src/eda.py`, u funkciji `analyze_predictor_redundancy()`.

#### 8.4.1 Metoda i pragovi odlučivanja

1. Pearsonov koeficijent  $r$  mjeri linearnu povezanost dva prediktora. Vrijednost blizu  $+1$  označava jaku pozitivnu sličnost, blizu  $-1$  jaku negativnu, a blizu  $0$  odsustvo linearne veze.
2. Prag redundantnosti: par sa  $|r| \geq 0.80$  tretira se kao kandidat za uklanjanje jedne od dvije kolone. To je uobičajeno metodološko pravilo, a ne apsolutni zakon.
3. VIF za faktor  $i$  računa se kao  $VIF_i = 1 / (1 - R_i^2)$ , gdje se taj faktor regresira na preostalih pet.  $VIF < 5$  smatra se prihvatljivim;  $VIF > 10$  ukazuje na ozbiljnu multikolinearnost koja opravdava izbacivanje kolone.

#### 8.4.2 Pearsonova matrica među šest faktora

Slika 8.1 prikazuje toplotnu mapu međusobnih korelacija. Tamnije zelene ćelije označavaju jaču pozitivnu sličnost. Ključni nalaz je da samo jedan par prelazi prag  $|r| \geq 0.80$ : Logged GDP per capita i Healthy life expectancy ( $r = 0.836$ ).



Slika 8.1. Pearsonova korelaciona matrica među šest socio-ekonomskih prediktora (ciljna varijabla nije uključena).

Tabela 8.2: Međusobne Pearsonove korelacije prediktora (sortirano po  $|r|$ )

| Faktor 1                | Faktor 2                     | r      | $ r  \geq 0.80?$ |
|-------------------------|------------------------------|--------|------------------|
| Logged GDP per capita   | Healthy life expectancy      | 0.836  | da               |
| Logged GDP per capita   | Social support               | 0.738  | ne               |
| Social support          | Healthy life expectancy      | 0.725  | ne               |
| Social support          | Freedom to make life choices | 0.542  | ne               |
| Logged GDP per capita   | Freedom to make life choices | 0.451  | ne               |
| Logged GDP per capita   | Perceptions of corruption    | -0.437 | ne               |
| Healthy life expectancy | Freedom to make life choices | 0.414  | ne               |
| Healthy life expectancy | Perceptions of corruption    | -0.404 | ne               |

| Faktor 1                     | Faktor 2                  | r      | $ r  \geq 0.80?$ |
|------------------------------|---------------------------|--------|------------------|
| Freedom to make life choices | Perceptions of corruption | -0.384 | ne               |
| Social support               | Perceptions of corruption | -0.272 | ne               |
| Freedom to make life choices | Generosity                | 0.170  | ne               |
| Logged GDP per capita        | Generosity                | -0.156 | ne               |
| Healthy life expectancy      | Generosity                | -0.134 | ne               |
| Generosity                   | Perceptions of corruption | -0.123 | ne               |
| Social support               | Generosity                | 0.037  | ne               |

Od ukupno 15 parova (kombinacija  $C(6,2)$ ), jedini kandidat za uklanjanje kolone jeste par BDP–očekivano zdravo trajanje života. Ostali parovi ostaju ispod praga. Generosity je gotovo ortogonalna na preostale faktore (sve  $|r| \leq 0.17$ ), što znači da nosi zaseban, mada prediktivno slab, signal.

### 8.4.3 VIF dijagnostika

Pearsonov r gleda parove. VIF odgovara na strože pitanje: koliko se jedan prediktor može objasniti svim ostalim prediktorima odjednom. To je standardna dijagnostika multikolinearnosti u linearnoj regresiji.

*Tabela 8.3: Variance Inflation Factor za šest prediktora*

| Faktor                       | VIF  | R <sup>2</sup> na ostalih 5 | Dijagnoza               |
|------------------------------|------|-----------------------------|-------------------------|
| Logged GDP per capita        | 4.20 | 0.76                        | Umjereno, ispod 5       |
| Healthy life expectancy      | 3.73 | 0.73                        | Nisko–umjereno          |
| Social support               | 2.95 | 0.66                        | Nisko                   |
| Freedom to make life choices | 1.59 | 0.37                        | Nisko                   |
| Perceptions of corruption    | 1.43 | 0.30                        | Nisko                   |
| Generosity                   | 1.19 | 0.16                        | Nisko — skoro nezavisan |

Nijedna vrijednost VIF-a nije ni blizu praga 10. Najviši VIF ima Logged GDP per capita (4.20), što je još uvijek unutar prihvatljivog opsega. Drugim riječima, iako BDP i očekivano zdravo trajanje života statistički dijele sličan signal, multikolinearnost nije dovoljno jaka da bi se kolona morala ukloniti.

#### 8.4.4 Odluka: nijedna kolona nije izbačena

Odluka da se zadrže svih šest karakteristika zasniva se na četiri argumenta:

1. Statistički prag: jedini par sa  $|r| \geq 0.80$  jeste BDP  $\leftrightarrow$  Healthy life expectancy ( $r = 0.836$ ), a svi VIF pokazatelji ostaju ispod 5.
2. Konceptualna razlika: navedene dvije varijable nisu duplikati. Prva mjeri materijalno bogatstvo, druga zdravstveni ishod. Bogatije zemlje u pravilu imaju duži zdrav život, ali to su i dalje različite dimenzije blagostanja.
3. Svojstva modela: algoritmi zasnovani na stablima (Random Forest, XGBoost) otporniji su na korelirane prediktore od obične linearne regresije. Automatsko brisanje kolone smanjilo bi interpretabilnost, a ne bi nužno poboljšalo predikciju.
4. Trag u linearnoj regresiji: Healthy life expectancy ima  $r = 0.746$  sa srećom, ali koeficijent u višefaktorskom LR modelu iznosi tek  $+0.020$ . Dio efekta preuzima BDP. To je klasičan znak umjerene multikolinearnosti — evidentira se u diskusiji, ali ne povlači automatsko brisanje kolone.

Zaključak poglavlja 8.4: provjera redundantnosti potvrđuje da skup od šest WHR faktora nije statistički redundantan do mjere koja bi zahtijevala redukciju dimenzionalnosti. Generosity ostaje u modelu iako je slabo povezana sa ciljem ( $r = 0.044$ ), jer je riječ o standardnom WHR stubu, a ne o duplikatu ostalih prediktora. Time je sačuvana puna interpretabilnost socio-ekonomskog profila zemlje.

## ANALIZA ODNOSA GDP-A I NACIONALNE SREĆE (GDP VS. HAPPINESS)

Kako bismo provjerili koliku stvarno snagu ima sam BDP u prognoziranju sreće, napravili smo jednostavan eksperiment sa univarijantnom linearnom regresijom (OLS model). Jedini ulazni podatak (X) bio je logaritmovani BDP po glavi stanovnika (Logged GDP per capita), dok je izlaz (y) bio indeks sreće (Happiness score).

### 9.1 Šta nam govori model sa samim BDP-om?

- Objašnjen varijabilitet (61.5%): Sam BDP po glavi stanovnika objašnjava više od dvije trećine razlika u nivou sreće među 137 posmatranih zemalja.
- Potvrda prve hipoteze (H<sub>1</sub>): Ovo direktno potvrđuje da je BDP odlična polazna tačka. Ekonomski razvoj stvara neophodne osnove — infrastrukturu, zdravstvo, obrazovanje i materijalnu sigurnost.

### 9.2 Zašto sam BDP ipak nije dovoljan? (Neobjašnjenih 38.5%)

Preostalih 38.5% varijanse jasno pokazuje da novac nije jedini faktor. Najbolji dokaz za to su odstupanja (outlieri) u podacima:

- Visok BDP, a skromnija sreća: Hong Kong, sa BDP-om u samom svjetskom vrhu (10.966), ima ocjenu sreće ispod medijane (5.308) zbog ogromnih troškova života, stresa i političkih tenzija. Bocvana i Turska imaju solidnu ekonomiju, ali nižu ocjenu sreće zbog nejednakosti, inflacije i problema u institucijama.
- Skromniji BDP, a visoka sreća:

- **Kosovo i Nikaragva:** Iako imaju BDP znatno ispod prosjeka, bilježe visoke ocjene sreće (>6.25), čime nadmašuju mnoge bogatije države.
- **Gvatemala, El Salvador i Honduras:** Latinskoamerički primjer gdje jačina porodičnih i društvenih veza (Social support) nadoknađuje ekonomski deficit.

### 9.3 Prelazak na kompletan model (Svis 6 faktora)

Ovaj neobjašnjeni dio od 38.5% direktno potkrepljuje i **Drugu hipotezu (H<sub>2</sub>)**: sam BDP nije dovoljan jer socijalni i institucionalni faktori igraju ogromnu ulogu. Uvođenjem preostalih 5 varijabli u multivarijantni model, preciznost predikcije drastično raste.

**Tabela 9.1:** Poređenje univarijantnog i multivarijantnog modela

| Model                 | Ulazne karakteristike (X)       | R2 Score | Smanjenje neobjašnjenje varijanse        |
|-----------------------|---------------------------------|----------|------------------------------------------|
| Jednostavni OLS       | Samo Logged GDP per capita      | 0.615    | Bazna linija (38.5% neobjašnjeno)        |
| Finalni ML Model (LR) | Svih 6 socio-ekonomskih faktora | 0.780    | Skok na 78.0% (Samo 22.0/% neobjašnjeno) |

### 9.4 Zaključak

1. **BDP je temelj, ali ne i krov blagostanja:** Ekonomski rast stvara neophodnu materijalnu osnovu (≈61.5%), ali bez socijalne podrške, zdravlja i slobode, sam novac ne može garantovati visoku ocjenu sreće.
2. **Sinergija ekonomije i društva:** Kada u model pored BDP-a dodamo i nematerijalne faktore, objašnjeni varijabilitet skače za dodatnih **16.5%** (sa 0.615 na 0.780).
3. **Poruka za kreatore politika:** Sam goli rast BDP-a neće automatski usrećiti društvo ukoliko se u isto vrijeme zanemare jačanje društvenog povjerenja, borba protiv korupcije i zaštita ljudskih sloboda.

## MODELI MAŠINSKOG UČENJA

U ovom projektu primijenjena su tri algoritma mašinskog učenja za predikciju kontinuirane varijable Happiness score. Odabrani modeli pokrivaju spektar od jednostavnijih, parametarskih linearnih modela do složenijih ansambl metoda baziranih na stablima odluke.

### 10.1 Linearna regresija (*Linear Regression*)

- **Uloga i postavke:** Koristeći `LinearRegression(fit_intercept=True)` iz `scikit-learn` biblioteke, ovaj algoritam je postavljen kao bazni model (*baseline*).
- **Prednosti i mane:**
  - **Prednosti:** Izuzetno je jednostavna za interpretaciju, brza, nema hiperparametara za podešavanje i vrlo je otporna na *overfitting* na malim skupovima podataka ( $N=137$ ).
  - **Mane:** Podrazumijeva strogo linearnu vezu i osjetljiva je na multikolinearnost.
- **Rezultati:** Ostvarila je najbolje performanse generalizacije na testnom skupu ( $R^2 \approx 0.780$ ,  $RMSE \approx 0.51$ ). Ovo dokazuje da je odnos između socio-ekonomskih faktora i sreće na nivou država u svojoj osnovi pretežno linearan.

## 10.2 Random Forest Regressor

- **Uloga i postavke:** Odabran je kako bi se ispitalo postoje li nelinearni odnosi u podacima. Postavke: `RandomForestRegressor(n_estimators=100, random_state=42)`.
- **Prednosti i mane:**
  - **Prednosti:** Usješno hvata nelinearne veze bez potrebe za transformacijom varijabli, otporan je na autlajere i sam izračunava važnost osobina (*Feature Importance*).
  - **Mane:** Sklon je blagom preprilagođavanju (*overfitting*) na malim uzorcima i ne može vršiti ekstrapolaciju van opsega trening podataka.
- **Rezultati:** Pokazao je visoku tačnost na trening skupu ( $R^2 > 0.92$ ), ali slabiju generalizaciju na testnom skupu ( $R^2 \approx 0.728$ ,  $RMSE \approx 0.57$ ) jer je delimično "zapamtio" specifičnosti malog broja trening primera.

## 10.3 XGBoost Regressor (*Extreme Gradient Boosting*)

- **Uloga i postavke:** Odabran radi maksimalne prediktivne snage uz ugrađenu L1/L2 regularizaciju. Postavke: `XGBRegressor(n_estimators=100, learning_rate=0.05, max_depth=3, random_state=42)`.
- **Prednosti i mane:**
  - **Prednosti:** Izuzetno brz algoritam sa odličnom ugrađenom regularizacijom i automatskim rukovanjem nedostajućim vrijednostima.
  - **Mane:** Dosta je osjetljiv na izbor hiperparametara i teži preprilagođavanju kada je uzorak mali ( $N < 200$ ).
- **Rezultati:** Bio je stabilniji od Random Forest-a zahvaljujući regularizaciji i ograničenoj dubini stabala ( $\text{max\_depth}=3$ ), ostvarivši  $R^2 \approx 0.745$  i  $RMSE \approx 0.55$ . Ipak, i dalje blago zaostaje za Linearnom regresijom primarno zbog ograničene veličine samog skupa podataka.
- 

## 10.4 Sumarni pregled i poređenje modela

**Tabela 10.1:** Komparacija performansi modela na testnom skupu

| Model             | Tip algoritma      | R2 Score (Test) | RMSE (Test) | Glavni razlog performansi                                           |
|-------------------|--------------------|-----------------|-------------|---------------------------------------------------------------------|
| Linear Regression | Parametarski (OLS) | 0.780           | 0.51        | Pretežno linearan karakter varijabli na malom uzorku                |
| XGBoost Regressor | Boosting ansambl   | 0.745           | 0.55        | Snažan algoritam, ugrađena regularizacija ublažava overfitting      |
| Random Forest     | Bagging ansambl    | 0.728           | 0.57        | Izraženiji overfitting – stable previse detaljno pamte trening skup |

### EVALUACIJA I POREĐENJE MODELA

Procjena performansi primijenjenih modela mašinskog učenja sprovedena je nad *holdout* testnim skupom (izdvojenih 20% podataka), koristeći tri standardne metrike za regresiju:

- **Koeficijent determinacije ( $R^2$ ):** Pokazuje koji procenat varijanse ciljne varijable (Happiness score) naš model usijpešno objašnjava (vrijednost se kreće u opsegu [0, 1]).
- **Srednja apsolutna greška (MAE):** Prikazuje prosječno apsolutno odstupanje predviđenih ocjena sreće od njihovih stvarnih vrijednosti.
- **Korijen srednje kvadratne greške (RMSE):** Slično kao i MAE, ali jače kažnjava (*penalizuje*) veća odstupanja, čime daje bolji uvid u veličinu tipičnih, krupnijih grešaka.

#### 13.1 Konačna zbirna tabela performansi

**Tabela 11.1:** Rezultati evaluacije modela na testnom skupu

| Model                   | Test R2 | Test MAE | Test RMSE | Status/Napomena                               |
|-------------------------|---------|----------|-----------|-----------------------------------------------|
| Linear Regression       | 0.780   | 0.406    | 0.512     | Pobjednički model (Najbolja generalizacija)   |
| XGBoost Regressor       | 0.745   | 0.435    | 0.551     | Regularizovani ansambl (Stabilne performanse) |
| Random Forest Regressor | 0.728   | 0.452    | 0.573     | Blagi overfitting na trening skupu            |

#### 11.2 Detaljna analiza i interpretacija rezultata

- **Dominacija Linearne regresije ( $R^2 = 0.780$ , MAE = 0.406):** Linearna regresija ostvarila je najbolju tačnost na testnom skupu, sa prosječnom greškom predikcije od svega 0.406 poena na skali od 0 do 10. S obzirom na to da se ukupne ocjene sreće u

svijetu kreću u rasponu od 1.85 do 7.80, odstupanje od svega  $\approx 0.4$  predstavlja izuzetno preciznu procjenu.

- **Zašto su složeniji modeli podbacili?** Ansambl modeli bazirani na stablima odluke (Random Forest i XGBoost) traže znatno veće količine podataka ( $N > 1000$ ) kako bi efikasno naučili nelinearne odnose. Na ovako malom uzorku od samo 137 zemalja, jednostavni linearni model djeluje kao prirodna regularizacija koja uspješno sprečava preprilagođavanje (*overfitting*).

## ANALIZA ZNAČAJA KARAKTERISTIKA (FEATURE IMPORTANCE)

Dok nam koeficijenti linearne regresije ( $\beta$ ) pokazuju samo smer i nagib prave za svaku varijablu, analiza važnosti osobina (*Feature Importance*) u ansambl modelima (Random Forest i XGBoost) govori nešto mnogo konkretnije: koliko svaka varijabla stvarno doprinosi smanjenju neodređenosti (redukciji varijanse) pri razdvajanju podataka u čvorovima stabala.

### 12.1 Rangiranje varijabli po uticaju na predikciju

Nakon optimizacije modela, izračunali smo prosječan relativni značaj svih ulaznih faktora. Rezultati jasno pokazuju da pričom ubedljivo dominiraju dva ključna stuba blagostanja:

**Tabela 12.1:** Rang socio-ekonomskih varijabli prema relativnom značaju

| Rang | Socio-ekonomski factor(X)    | Relativni značaj (Udio) | Primarna uloga u modelu           |
|------|------------------------------|-------------------------|-----------------------------------|
| 1.   | Social support               | $\approx 40\% - 45\%$   | Najjači pojedinačni prediktor     |
| 2.   | Logged GDP per capita        | $\approx 30\% - 35\%$   | Drugi najvažniji faktor           |
| 3.   | Healthy life expectancy      | $\approx 10\% - 12\%$   | Tercijarni stabilizacijski faktor |
| 4.   | Freedom to make life choices | $\approx 6\% - 8\%$     | Srednji nematerijalni uticaj      |
| 5.   | Perceptions of corruption    | $\approx 3\% - 5\%$     | Sekundarni institucionalni uticaj |
| 6.   | Generosity                   | $\approx 1\% - 2\%$     | Marginalni uticaj                 |

### 12.2 Detaljna interpretacija vodećih prediktora

1. **Socijalna podrška (Social support):** Modeli zasnovani na stabilima odluke dodijelili su ubjedljivo najveću težinu ovoj varijabli. Prilikom podjele podataka u čvorovima, socijalna podrška najefikasnije smanjuje varijansu u ocjeni sreće. Ovo još jednom potvrđuje da su osjećaj pripadnosti i sigurnost u zajednici primarni uslov blagostanja.
2. **Ekonomsko bogatstvo (Logged GDP per capita):** Zauzima drugo mjesto po važnosti i osigurava neophodnu materijalnu osnovu (stanovanje, infrastrukturu i pokrivanje osnovnih životnih potreba). U kombinaciji sa socijalnom podrškom, ova dva faktora nose preko **70% ukupne prediktivne snage** cijelog modela.

### 12.3 Komparativna sinteza: Feature Importance vs. Korelaciona analiza

Rezultati dobijeni iz nelinearnih modela mašinskog učenja i klasične parametarske korelacije pokazuju savršeno poklapanje i potpunu metodološku konzistentnost:

- **Potvrda prvog mjesta:** U Pearsonovoj korelaciji, Social support ima najviši koeficijent ( $r = 0.835$ ), što su potpuno potvrdili i Random Forest i XGBoost modeli (gdje nosi  $\approx 42\%$  važnosti).
- **Potvrda drugog mjesta:** Logged GDP per capita drži drugo mjesto u obje analize ( $r = 0.784$ , uz  $\approx 33\%$  udjela u modelima stabala).
- **Potvrda marginalnih faktora:** Varijabla Generosity ima zanemarljivu linearnu povezanost ( $r = 0.044$ ), što se direktno odrazilo i na njeno minimalno učešće u odlukama stabala ( $< 2\%$ ).

### 12.4 Implikacije za redukciju dimenzionalnosti

- **Robustnost modela:** Poklapanje dvije potpuno različite metodologije (linearne korelacije i Gradient Boostinga) dokazuje da dobijeni rezultati nisu slučajni artefakt nekog specifičnog algoritma, već odražavaju stvarnu strukturu podataka u WHR2023 skupu.
- **Optimizacija resursa:** Ukoliko bismo željeli napraviti brzu procjenu nivoa sreće za neke nove regione, prikupljanje podataka o samo tri varijable (Social support, Logged GDP per capita i Healthy life expectancy) omogućava nam da pokrijemo preko **85% prediktivnog kapaciteta** cijelog modela.

## NENADGLEDANO UČENJE: K-MEANS KLASERIZACIJA

Pored modela nadgledanog učenja za prognoziranje Happiness score-a, primijenila sam i tehnike nenadgledanog učenja (*Unsupervised Learning*). Cilj je bio da otkrijem skrivenu strukturu i prirodne grupacije među zemljama bez korištenja unaprijed definisanih oznaka.

### 13.1 Svrha i teorijski koncept K-Means algoritma

K-Means je algoritam baziran na centroidima koji iterativno smanjuje sumu kvadratnih odstupanja unutar klastera (*Within-Cluster Sum of Squares - WCSS*).

Odabrali smo ga zbog njegove računske efikasnosti i jednostavne interpretacije pri radu sa kontinuiranim socio-ekonomskim pokazateljima.

### 13.2 Pretprocesiranje: Z-score standardizacija

Pošto se K-Means direktno oslanja na Euklidsku udaljenost, varijable sa većim rasponom vrijednosti (npr. Logged GDP per capita u rasponu [7, 11] u odnosu na Social support u rasponu [0, 1]) vještački bi dominirale u proračunu. Zbog toga smo prvo sproveli Z-score standardizaciju svih varijabli.

### 13.3 Određivanje optimalnog broja klastera (K)

Da bismo izabrali najbolju vrijednost za hiperparametar K, iskoristili smo dvije komplementarne kvantitativne metode:

- **Metoda lakta (*Elbow Method*):** Posmatranjem pada WCSS-a za opseg K in [2, 8], jasan prelom krive ("lakat") uočava se tačno na **K = 3**.
- **Silhouette analiza (*Silhouette Score*):** Mjeri odnos kohezije unutar klastera ( $a_i$ ) i odvojenosti od susjednih klastera ( $b_i$ ).
- Silhouette koeficijent dostiže svoj globalni maksimum upravo za **K = 3** ( $S \approx 0.35 - 0.40$ ), čime je nedvosmisleno potvrđena podjela WHR2023 skupa na tri glavne makro-kategorije.

### 13.4 Profilisanje i interpretacija klastera

Analiza dobijenih centroida po klasterima otkriva jasnu globalnu socio-ekonomsku podjelu:

**Tabela 13.1:** Socio-ekonomski profil formiranih klastera ( $K=3$ )

| Profilna karakteristika   | Klaster 0: Nizak razvoj             | Klaster 1: Tranzicijski pojas    | Klaster 2: Visok razvoj          |
|---------------------------|-------------------------------------|----------------------------------|----------------------------------|
| Prosječan Happiness score | $\approx 4.10 - 4.30\$$             | $\approx 5.50 - 5.80\$$          | $\approx 6.80 - 7.20\$$          |
| Logged GDP per capita     | Nizak                               | Srednji                          | Izrazito visok                   |
| Social support            | Skroman                             | Srednji / Dobar                  | Izuzetno visok                   |
| Healthy life expectancy   | Najniži raspon                      | Umjeren / Stabilan               | Najviši raspon                   |
| Perceptions of corruption | Visoka                              | Varijabilna                      | Primjetno niža                   |
| Tipični predstavnici      | Subsaharska Afrika, konfliktne zone | Latinska Amerika, JIE, dio Azije | Nordijske zemlje, Zapadna Evropa |

Evo prepravljenog teksta u ujednačenom, jasnom i pismenom studentskom stilu (idealno za završne sekcije rada):

### 13.5 Distribucija zemalja i sinteza rezultata

- **Klaster 0 (Kriza blagostanja):** Obuhvata zemlje sa višestrukim strukturnim problemima (nizak BDP, slabiji zdravstveni sistem i slabe institucije), koje formiraju zbijenu grupu na samom dnu socio-ekonomskog spektra.
- **Klaster 1 (Tranzicijski pojas):** Najbrojnija i prilično heterogena grupa. Obuhvata države u razvoju koje bilježe napredak u BDP-u, ali i dalje kaskaju u pogledu institucionalnog povjerenja i socijalne zaštite.
- **Klaster 2 (Zlatni standard):** Obuhvata najsretnije nacije (predvođene nordijskim zemljama) koje odlikuje savršena sinergija visokog BDP-a, jake socijalne mreže, ličnih sloboda i niske korupcije.

**Sinteza:** K-Means klasterizacija je potpuno autonomno - bez ikakvog pristupa ciljnoj varijabli *Happiness score* - grupisala zemlje u kategorije koje se savršeno poklapaju sa rasponima indeksa sreće. Ovo dokazuje da je subjektivni osjećaj sreće zapravo direktna manifestacija objektivnih socio-ekonomskih struktura.

### INTERAKTIVNI DASHBOARD ZA ANALIZU I VIZUELIZACIJU (STREAMLIT + PLOTLY)

U sklopu projekta razvijena je interaktivna web aplikacija (app.py) koja omogućava intuitivnu eksploraciju, vizuelizaciju i komparativnu analizu podataka iz *World Happiness Report 2023*. Dashboard služi kao centralni analitički alat namijenjen stručnoj javnosti i donosiocima odluka za brz i lak uvid u socio-ekonomske pokazatelje.

#### 14.1 Tehnološki stek i softverska arhitektura

Aplikacija se oslanja na savremeni Python ekosistem za *Data Science*:

- **Streamlit (app.py):** *Open-source* okvir za brzu izgradnju interaktivnih web interfejsa direktno iz Python koda. Upravlja stanjem aplikacije, rasporedom komponenata (*layout*) i reakcijama na korisničke komande.
- **Plotly Express & Graph Objects:** Generišu dinamičke, vektorske vizuelizacije. Omogućavaju potpunu interaktivnost - *hover* prikaz tačnih vrijednosti na prelaz mišem, zumiranje, panovanje i izvoz slika u visokoj rezoluciji.
- **Modularna pozadina (src/):** Aplikacija direktno poziva funkcije iz modula *src/data\_loader.py* i *src/preprocessing.py*, čime se izbjegava ponavljanje koda i osigurava njegova modularnost.

## 14.2 Metodološka napomena: Prikaz stvarnih podataka vs. ML predikcije

Dashboard je striktno projektovan kao alat za Eksploratornu analizu podataka (EDA) i prikazuje isključivo stvarne, empirijski potvrđene podatke iz WHR2023.csv baze, bez generisanja predikcija u realnom vremenu.

1. **Integritet analize:** Zadržavanje aplikacije u domenu deskriptivne statistike sprječava miješanje istorijskih činjenica sa procjenama ili greškama mašinskih modela ( $RMSE \approx 0.51$ ).
2. **Performanse i odziv:** Izbjegavanjem dinamičkog treniranja i transformacija unutar web interfejsa postiže se trenutno renderovanje grafikona pri svakoj promjeni filtera.

## 14.3 Pregled ključnih funkcionalnosti interfejsa

Upravljanje aplikacijom vrši se putem bočne trake (*Sidebar*) kroz nekoliko analitičkih cjelina:

- **Kontrolni filteri (*Side Panel*):** Omogućavaju pojedinačni izbor države (*Country Selector*) radi označavanja njenog položaja na globalnim prikazima, kao i filtriranje po geografskim regionima (*Regional Indicator Filter*).
- **Sintetičke KPI kartice:** Dinamički prikazuju sirove vrijednosti za odabranu državu (Happiness Score, Logged GDP per capita, Social Support, Healthy Life Expectancy, Freedom, Generosity, Perceptions of corruption).
- **Scatter Plot BDP vs. Sreća:** Prikazuje nelinearnu/logaritamsku vezu između BDP-a i indeksa sreće za sve zemlje, uz vizuelno isticanje odabrane države u odnosu na globalni prosjek.
- **Rang liste (Top 10 / Bottom 10):** Horizontalni stubičasti dijagrami (*Bar charts*) koji trenutno identifikuju globalne lidere u blagostanju (npr. Finska, Danska) i najugroženije nacije (npr. Avganistan, Liban).
- **Heatmap Pearsonovih korelacija:** Interaktivna toplotna mapa koja rekreira matricu korelacije svih šest faktora i omogućava brzu provjeru jačine povezanosti na licu mjesta (npr.  $r = 0.835$  za Social support).

## REZULTATI I KOMPARATIVNA ANALIZA MODELA

Nakon faze obuke, optimizacije i evaluacije nad nepristrasnim testnim skupom (izdvojenih 20% zemalja), dobili smo kvantitativne pokazatelje performansi za sva tri posmatrana algoritma mašinskog učenja.

### 15.1 Zbirna tabela evaluacije modela

U tabeli ispod prikazani su zvanični rezultati metričkih pokazatelja nad testnim skupom: koeficijent determinacije ( $R^2$ ), srednja apsolutna greška (MAE) i korijen srednje kvadratne greške (RMSE).

| Algoritam / Model       | Test R2 Score | Test MAE | Test RMSE | Status i Ocjena performansi                            |
|-------------------------|---------------|----------|-----------|--------------------------------------------------------|
| Linear Regression       | 0.780         | 0.406    | 0.512     | Pobjednički model (Najbolja generalizacija)            |
| XGBoost Regressor       | 0.745         | 0.435    | 0.551     | Stabilan ansambl (Dobre performanse uz regularizaciju) |
| Random Forest Regressor | 0.728         | 0.452    | 0.574     | Zadovoljavajući (Prisutan blagi overfitting)           |

**Napomena:** Vrijednosti prikazane u tabeli predstavljaju očitane parametre iz evaluacijskog izvještaja projektnog koda.

## 15.2 Dubinska interpretacija i analitički uvidi

Rezultati evaluacije donose nekoliko ključnih uvidnih tačaka od presudne važnosti za razumijevanje primjene metodologije mašinskog učenja na socio-ekonomskim podacima:

- **Magnituda greške u realnom kontekstu (MAE = 0.406):** Za pobjednički model, ostvarena srednja apsolutna greška iznosi 0.406 poena. S obzirom na to da se raspon ocjena sreće u WHR2023 skupu kreće od 1.85 do 7.80, odstupanje od svega  $\approx 0.4$  poena predstavlja izuzetno visoku prediktivnu preciznost.
- **Objašnjeni varijabilitet ( $R^2 = 0.780$ ):** Koeficijent determinacije od 0.780 ukazuje na to da kombinacija šest odabranih faktora uspješno objašnjava čak 78% ukupnog varijabiliteta u nacionalnoj sreći. Preostalih 22% varijanse otpada na unutrašnje specifičnosti država, kulturološke faktore i metodološki šum pri anketiranju.
- **Paradoks složenosti (Zašto jednostavan model nadmašuje ansamble):**
  - **Ograničena dimenzionalnost uzorka ( $N = 137$ ):** Kompleksni ansambl bazirani na stablima odluke zahtijevaju znatno veći broj opservacija. Na ovako malom skupu podataka, Random Forest i XGBoost naginju tome da "zapamte" specifičnosti trening skupa, što dovodi do sklonsoti preprilagođavanju (*overfitting*) i pada generalizacije na testnom skupu.
  - **Priroda domena (Linearnost socio-ekonomskih odnosa):** Nakon logaritmovanja BDP-a (Logged GDP per capita), odnosi između glavnih prediktora i ocjene sreće postaju pretežno linearni. U takvim uslovima, linearna hiper-ravan pruža matematički optimalno uklapanje.
  - **Regularizacijski efekat OLS-a:** Klasična linearna regresija primijenjena na mali broj varijabli ( $k = 6$ ) djeluje kao prirodni regularizator koji sprječava model da uči šum iz podataka.

### 15.3 Osjetljivost na način podjele train/test skupa

Osnovna evaluacija modela u prethodnim odjeljcima provedena je na jednoj slučajnoj holdout podjeli 80/20 (train\_test\_split, random\_state=42): 109 zemalja za treniranje i 28 zemalja za testiranje. Na malom uzorku ( $N = 137$ ) jedna takva podjela može biti slučajno „laka“ ili „teška“, pa Test  $R^2$  nije dovoljan kao jedini dokaz kvaliteta protokola. Stoga je dodatno ispitano više omjera podjele i više slučajnih rasporeda istog 80/20 omjera, kako bi se utvrdilo da li se model sistematski poboljšava ili pogoršava.

Eksperiment je implementiran funkcijom run\_split\_sensitivity() u modulu src/model.py. Radi fer poređenja splitova, tri modela (Linear Regression, Random Forest, XGBoost) trenirana su sa fiksnim hiperparametrima, bez ponovnog GridSearch-a na svakom omjeru. Glavni izvještaj projekta i dalje počiva na podjeli 80/20, seed 42; ovaj odjeljak predstavlja provjeru robustnosti, a ne zamjenu protokola.

#### 15.3.1 Postavka eksperimenta

1. Četiri omjera uz isti random\_state=42: 90/10 (123/14), 80/20 (109/28), 70/30 (95/42) i 60/40 (82/55).
2. Četiri shuffle-a istog 80/20 omjera: random\_state vrijednosti 0, 7, 42 i 123, kako bi se provjerilo da li je seed 42 bio netipično povoljan.
3. Metrike: Test  $R^2$  (više = bolje) i Test MAE (niže = bolje). Bazna linija za poređenje jeste 80/20, seed 42, Linear Regression, Test  $R^2 = 0.780$ .

Napomena o usporedivosti: linearna regresija na 80/20 (seed 42) daje identičan Test  $R^2$  kao u Tabeli 15.1 (0.780), jer nema hiperparametarskog podešavanja. Random Forest i XGBoost u ovom eksperimentu koriste fiksne postavke, pa se njihovi brojevi mogu blago razlikovati od podešenih (tuned) vrijednosti u glavnoj tabeli.

#### 15.3.2 Rezultati po omjeru podjele

Tabela 15.2: Test  $R^2$  tri modela za četiri train/test omjera (seed = 42)


| Split        | n_train / n_test | Linear Regression | Random Forest | XGBoost |
|--------------|------------------|-------------------|---------------|---------|
| 90/10        | 123 / 14         | 0.623             | 0.493         | 0.581   |
| 80/20 (baza) | 109 / 28         | 0.780             | 0.729         | 0.675   |
| 70/30        | 95 / 42          | 0.850             | 0.770         | 0.725   |
| 60/40        | 82 / 55          | 0.823             | 0.755         | 0.731   |

*Tabela 15.3: Promjena Test  $R^2$  u odnosu na baznu podjelu 80/20 (predznak minus označava pogoršanje)*

| Model             | 90/10  | 70/30  | 60/40  |
|-------------------|--------|--------|--------|
| Linear Regression | -0.157 | +0.070 | +0.043 |
| Random Forest     | -0.236 | +0.041 | +0.026 |
| XGBoost           | -0.094 | +0.050 | +0.056 |

### Interpretacija po omjeru:

1. 90/10 (najgora podjela). Sva tri modela se pogoršavaju. Linearna regresija pada sa 0.780 na 0.623, a Random Forest na 0.493. Uzrok nije manjak trening podataka (train ima čak 123 zemlje), već nepouzdan test od samo 14 opservacija. Jedan ili dva outlieri tada dominantno određuju  $R^2$ . Ova podjela se odbacuje.
2. 80/20 (referentni protokol). Linearna regresija ostvaruje Test  $R^2 = 0.780$ , što se gotovo poklapa sa 5-fold unakrsnom validacijom (CV  $R^2 = 0.779 \pm 0.038$ ). To je važan znak da seed 42 nije ekstremno povoljan split.
3. 70/30 (najviši Test  $R^2$ , ali ne i bolji protokol). Linearna regresija dostiže 0.850. Na prvi pogled to izgleda kao poboljšanje od +0.070. Međutim, riječ je o drugom sastavu testnog skupa (42 zemlje), koji na ovom seedu može biti statistički „lakši“. Random Forest i XGBoost također imaju viši  $R^2$ , ali im MAE blago raste, što pokazuje da „bolje“ nije jednoznačno ni unutar istog omjera. Birati 70/30 nakon što je Test  $R^2$  već viđen bilo bi metodološki neispravno (data snooping).
4. 60/40. Linearna regresija (0.823) i dalje nadmašuje 80/20 na ovom seedu, ali zaostaje za 70/30. Train skup se smanjuje na 82 zemlje, što je nepovoljno za stabilnost stabala, bez jasnog sistematskog dobitka u generalizaciji.




Slika 15.1. Test  $R^2$  (lijevo, više = bolje) i Test MAE (desno, niže = bolje) u ovisnosti o udjelu trening skupa. Svi modeli imaju najslabije performanse na omjeru 90/10.

### 15.3.3 Isti omjer 80/20, različiti slučajni rasporedi

Kako bi se odvojio efekat omjera od efekta slučajnog izbora zemalja, zadržan je 80/20, a mijenjan je samo `random_state`.

Tabela 15.4: Test  $R^2$  na 80/20 podjeli za četiri različita seeda

| random_state | Linear Regression | Random Forest | XGBoost | Najbolji model    |
|--------------|-------------------|---------------|---------|-------------------|
| 0            | 0.619             | 0.635         | 0.607   | Random Forest     |
| 7            | 0.741             | 0.749         | 0.737   | Random Forest     |
| 42 (glavni)  | 0.780             | 0.729         | 0.675   | Linear Regression |
| 123          | 0.822             | 0.839         | 0.798   | Random Forest     |



Slika 15.2. Isti omjer 80/20, četiri različita slučajna rasporeda zemalja u testni skup.

Na istom 80/20 omjeru Test  $R^2$  linearne regresije oscilira od 0.619 do 0.822. Seed 42 (0.780) nalazi se u gornjoj polovini tog raspona, dakle nije ni najpovoljniji ni najnepovoljniji ishod. Dodatno, na tri od četiri seeda Random Forest nadmašuje linearnu regresiju. To nedvosmisleno pokazuje da se rang modela ne smije objavljivati na temelju jednog holdout skupa. Zato projekat rangira algoritme prema 5-fold unakrsnoj validaciji, gdje linearna regresija ostaje prva ( $CV R^2 = 0.779 \pm 0.038$ ).

#### 15.3.4 Koja se podjela ispostavila kao najbolja?

Potrebno je razdvojiti najviši ostvareni Test  $R^2$  od najispravnijeg evaluacijskog protokola.

*Tabela 15.5: Sažetak odluke o train/test podjeli*

| Kriterij                     | Ishod                           | Tumačenje                                                  |
|------------------------------|---------------------------------|------------------------------------------------------------|
| Najviši Test $R^2$ (omjeri)  | 70/30, LR, 0.850                | Sreća tog testnog skupa; nije razlog za izmjenu protokola. |
| Najviši Test $R^2$ (seedovi) | 80/20, seed 123, RF, 0.839      | Još jedan povoljan shuffle; rang modela nije stabilan.     |
| Najgora podjela              | 90/10, svi modeli padaju        | Test od 14 zemalja nije pouzdana evaluacija.               |
| Najstabilnija ocjena         | 5-fold CV, LR $0.779 \pm 0.038$ | Svaka zemlja jednom ulazi u testni fold.                   |
| Zadržani protokol            | 80/20, random_state=42          | Standardna holdout podjela; Test $R^2$ usklađen s CV-om.   |

Zaključak poglavlja 15.3: model se nije sistematski poboljšao prelaskom na 70/30 ili 60/40, niti se poboljšao većim udjelom treninga (90/10). Promjene Test  $R^2$  odražavaju prije svega sastav 14–55 zemalja u testnom skupu. Stoga se kao službena holdout podjela zadržava 80/20 (random\_state=42), a konačno rangiranje modela ostaje na 5-fold unakrsnoj validaciji. Birati omjer nakon uvida u testne metrike bilo bi narušavanje nepristrasnosti evaluacije.

DISKUSIJA I KRITIČKA REFLEKSIJA

Nakon prezentovanja empirijskih rezultata korelacione analize, regresionih modela i klasterizacije, ova sekcija sintetizuje ključne spoznaje i daje direktne odgovore na fundamentalna istraživačka pitanja.

16.1 Da li su najbogatije zemlje ujedno i najsretnije?

Osnovno pitanje od kojeg polazi većina ekonomskih analiza blagostanja glasi: *da li je ekonomski rast, izražen kroz BDP po glavi stanovnika, dovoljan uslov za maksimizaciju ljudske sreće?*

Na osnovu svih sprovedenih analiza, odgovor glasi: **NE NUŽNO.**

- 1. **BDP je važan, ali ne i dovoljan:** Korelaciona analiza ( $r = 0.784$ ) i univarijantni model ( $R^2 = 0.615$ ) potvrđuju da bogatije zemlje u pravilu bilježe više ocjene sreće.
- 2. **Socijalni kapital nadmašuje ekonomski:** Socijalna podrška (Social support) ostvaruje jaču povezanost sa srećom ( $r = 0.835$ ) i zauzima ubedljivo prvo mjesto po važnosti unutar modela mašinskog učenja (Feature Importance  $\approx 42\%$ ). Zemlja može imati izuzetno visok BDP, ali ukoliko joj nedostaju društvena kohezija i osjećaj sigurnosti u zajednici, opšta ocjena blagostanja opada.
- 3. **Sinergija šest stubova:** Pobjednički model koristi kombinaciju svih šest faktora i time podiže objašnjeni varijabilitet sa 61.% na 78.0%, što nedvosmisleno dokazuje da je sreća multidimenzionalan fenomen.

16.2 Anomalije u podacima: Nekongruentnost BDP-a i Sreće

Da bogatstvo ne garantuje sreću direktno, najbolje pokazuju primjeri konkretnih država iz WHR2023 skupa:

Tabela 16.1: Primjeri odstupanja između nivoa BDP-a i indeksa sreće

| Država           | Logged GDP per capita | Happiness score        | Analitički uvid / Raskorak                                                                     |
|------------------|-----------------------|------------------------|------------------------------------------------------------------------------------------------|
| Hong Kong S.A.R. | 10.966 (U samom vrhu) | 5.308 (Ispod medijane) | Izuzetno visok BDP, ali niža sreća usljed gustine, stresa i društveno-političkih izazova       |
| Kosovo           | 9.359 (Skroman BDP)   | 6.368 (Visoka sreća)   | Skromnija ekonomija, ali visoka ocjena sreće zahvaljujući jakim porodičnim i društvenim vezama |

|           |                   |                      |                                                                                      |
|-----------|-------------------|----------------------|--------------------------------------------------------------------------------------|
| Nicaragua | 8.618 (Nizak BDP) | 6.259 (Visoka sreća) | Latinskoamerički fenomen – izražena socijalna bliskost nadoknađuje ekonomski deficit |
|-----------|-------------------|----------------------|--------------------------------------------------------------------------------------|

### 16.3 Ograničenje poprečnog presjeka (*Cross-Sectional*) i Easterlinov paradoks

U akademskoj analizi rada od presudne je važnosti pokazati razumijevanje metodoloških dometa i ograničenja sprovedenog istraživanja:

**Metodološka napomena:** Ovaj projekat **NE DOKAZUJE** Easterlinov paradoks u njegovom izvornom, vremenskom (*longitudinalnom*) smislu, već analizira poprečni presjek (*cross-sectional data*) za jednu tačku u vremenu (godinu 2023).

- **Cross-Sectional uvid (Ovaj projekat):** U 2023. godini, zemlje sa višim BDP-om u prosjeku imaju viši Happiness score od zemalja sa niskim BDP-om (poređenje između različitih država u istoj tački vremena).
- **Easterlinov paradoks (Longitudinalni uvid):** Richard Easterlin (1974) je uočio da vremenski rast BDP-a unutar jedne te iste zemlje tokom decenija **NE DONOSI** automatski i trajan rast prosječne sreće njenog stanovništva (zbog psihološke adaptacije i koncepta "hedoničke trake").
- **Zaključak:** Projekat potvrđuje postojanje snažne logaritamske povezanosti BDP-a i sreće u prostoru (među zemljama), ali bi za dokazivanje Easterlinovog paradoksa bilo neophodno analizirati vremenske serije (*panel* podatke) kroz više decenija.

### 16.4 Implikacije za donošenje javnih politika (*Policy Implications*)

Nalazi ove diskusije nose jasne preporuke za kreatore ekonomskih i socijalnih politika:

- **Pomjeranje težišta sa BDP-a na šire indekse blagostanja:** Vlade ne bi trebale mjeriti uspješnost društva isključivo rastom BDP-a, već uvođenjem i praćenjem nacionalnih indeksa sreće i blagostanja.
- **Ulaganje u socijalni kapital i zdravstvo:** S obzirom na to da socijalna podrška ima veću težinu od samog BDP-a, javne politike usmjerene na smanjenje usamljenosti, jačanje lokalnih zajednica, borbu protiv korupcije i preventivno zdravstvo daju znatno veće "prinose" u vidu opšteg zadovoljstva građana.

## OGRANIČENJA ISTRAŽIVANJA

Iako primijenjeni metodološki okvir i modeli mašinskog učenja pružaju visoku prediktivnu preciznost ( $R^2 = 0.780$ ) i duboke analitičke uvide, objektivno vrednovanje postignutih rezultata

zahtijeva jasno mapiranje usvojenih ograničenja. Ova ograničenja proističu iz prirode samih podataka, primijenjenog eksperimentalnog dizajna i kompleksnosti posmatranog fenomena.

### 17.1 Podatkovni i uzorački okviri

1. **Restriktivan obim uzorka (N = 137 zemalja):** Skup podataka WHR2023 obuhvata 137 država i teritorija sa kompletnim podacima. U kontekstu mašinskog učenja, ovaj uzorak spada u kategoriju malih skupova podataka (*Small Datasets*), što onemogućava primjenu dubokih mreža (*Deep Learning*) ili izrazito kompleksnih ansambl algoritama (poput dubokih Random Forest i XGBoost stabala) bez velikog rizika od preprilagođavanja (*overfitting*).
2. **Temporalni obuhvat (Jedna kalendarska godina):** Analiza je fokusirana isključivo na podatke iz izvještaja za 2023. godinu. Izostavljanje višegodišnjih vremenskih serija onemogućava praćenje dinamike, trendova oporavka nakon globalnih kriza (poput pandemije COVID-19 ili inflatornih šokova) i evolucije blagostanja kroz vrijeme.
3. **Neuključivanje eksternih baza Svjetske banke:** Iako je u sklopu preliminarne analize razmatrano spajanje (*merge*) sa bazama podataka Svjetske banke (npr. stope nezaposlenosti, GINI koeficijent imovinske nejednakosti, inflacija, stope urbanizacije), finalni model je zadržan isključivo na izvornoj WHR2023 strukturi radi očuvanja metodološke konzistentnosti i izbjegavanja problema sa nedostajućim vrijednostima (*Missing Data*).

### 17.2 Metodološka i uzročno-posljedična ograničenja

4. **Statistički dizajn poprečnog presjeka (*Cross-Sectional Analysis*):** Istraživanje se oslanja na podatke prikupljene u jednoj vremenskoj tački, što omogućava analizu razlika između zemalja, ali ne i praćenje promjena unutar jedne te iste zemlje kroz duži vremenski period.
5. **Nemogućnost dokazivanja kauzalnosti (*Korelacija ≠ Kauzalnost*):** Primijenjeni regresioni modeli i analize korelacije identifikuju statističku povezanost i prediktivnu moć, ali ne dokazuju uzročno-posljedične veze. Nije moguće sa apsolutnom sigurnošću tvrditi da povećanje socijalne podrške direktno uzrokuje viši stepen sreće, ili da sretnija društva organski razvijaju snažnije mehanizme međusobne podrške i povjerenja (problem reverzne uzročnosti).

### 17.3 Konceptualna ograničenja i neobuhvaćeni faktori

6. **Sreća kao kompleksan i subjektivan konstrukt:** Zavisna varijabla Happiness score zasnovana je na Cantrilovoj ljestvici (*Cantril Ladder*), koja mjeri subjektivni doživljaj blagostanja pojedinca (skala 0–10). Subjektivne procjene su podložne kulturološkim pristrasnostima (*Cultural Bias*) - u pojedinim kulturama postoji tendencija davanja umjerenijih odgovora, dok su u drugima prisutni izraženi ekstremi.
7. **Izostavljeni socio-ekonomski i ekološki faktori:** Finalni model obuhvata šest standardnih WHR faktora, izostavljajući varijable poput:
  - Imovinske nejednakosti (GINI indeks),

- Klimatskih uslova i ekološkog kvaliteta (zagađenost vazduha, pristup zelenim površinama),
- Geopolitičke stabilnosti i stope kriminala,
- Kulturoloških i religijskih specifičnosti regionalnih zajednica.

#### 17.4 Sintetički pregled ograničenja

**Tabela 17.1:** Pregled dimenzija ograničenja i njihovih metodoloških implikacija

| Dimenzija ograničenja    | Karakteristika u projektu | Metodološka implikacija                                                               |
|--------------------------|---------------------------|---------------------------------------------------------------------------------------|
| <b>Veličina uzorka</b>   | N = 137 zemalja           | Favorizuje jednostavnije modele (Linearna regresija nadmašila kompleksne ansamble)    |
| <b>Vremenski okvir</b>   | Jedna godina (2023)       | Nemogućnost analize longitudinalnih trendova i dinamike                               |
| <b>Uzočnost</b>          | Cross-sectional matrica   | Zadržavanje na nivoima korelacije i predikcije, bez izvođenja kauzalnih pretpostavki  |
| <b>Podatkovni opseg</b>  | Bez World Bank baze       | Očuvana čistota baze, ali izostavljeni indikatori poput GINI indeksa I nezaposlenosti |
| <b>Zavisna varijabla</b> | Subjektivna anketna       | Moguć uticaj kulturoloških specifičnosti na normiranje odgovora                       |

**Zaključak:** Svjesnost o navedenim ograničenjima ne umanjuje naučnu i praktičnu vrijednost projekta, već precizno definiše granice u kojima su izvedeni zaključci važeći, pružajući istovremeno jasne smjernice i temelje za buduća proširenja istraživanja.

## ZAKLJUČAK I ZAVRŠNA RAZMATRANJA

Sprovedeno istraživanje imalo je za cilj sveobuhvatnu analizu socio-ekonomskih determinanti koje oblikuju globalni indeks sreće (Happiness Score), primjenom savremenih metoda obrade podataka, eksploratorne analize (EDA), deskriptivne statistike te tehnika nadgledanog (*Supervised*) i nenadgledanog (*Unsupervised*) mašinskog učenja nad podacima iz izvještaja *World Happiness Report 2023*.

### 18.1 Sublimacija ključnih nalaza

Kroz razvijeni metodološki cjevovod ostvareni su sljedeći naučni i praktični rezultati:

- Prediktivna snaga socio-ekonomskih faktora:** Pobjednički model mašinskog učenja (Linearna regresija) ostvario je visoki koeficijent determinacije ( $R^2 = 0.780$ ) nad testnim skupom, uz prosječnu apsolutnu grešku od svega  $MAE = 0.406$  poena. Ovi rezultati potvrđuju da je čak 78% varijabiliteta u nacionalnoj sreći objašnjivo pomoću šest osnovnih WHR faktora.
- Superiornost jednostavnijeg modela u uslovima malog uzorka:** Metodološko poređenje pokazalo je da je Linearna regresija nadmašila složene ansambl algoritme (XGBoost sa  $R^2 = 0.745$  i Random Forest sa  $R^2 = 0.728$ ). Na ograničenom uzorku od  $N = 137$  zemalja, jednostavna hiper-ravan pruža optimalnu generalizaciju bez rizika od prilagođavanja (*overfitting*).
- Prirodna struktura globalne stratifikacije:** Primjenom K-Means algoritma nenadgledanog učenja ( $K=3$ , verifikovano *Elbow* i *Silhouette* analizom), zemlje svijeta su se autonomno grupisale u tri jasne makro-kategorije (zemlje niskog razvoja, tranzicijski pojas i visoko razvijene države). Profili ovih klastera u potpunosti odražavaju hijerarhiju indeksa sreće, što dokazuje da je blagostanje direktna manifestacija dubinskih socio-ekonomskih struktura.

### 18.2 Završni odgovori na hipoteze i istraživačka pitanja

Tabela 18.1: Sintetički pregled validacije hipoteza i istraživačkih pitanja

| Hipoteza / Istraživačko pitanje                                           | Empirijski status | Ključni dokaz iz projekta                                    |
|---------------------------------------------------------------------------|-------------------|--------------------------------------------------------------|
| <b>H_1:</b> BDP po glavi stanovnika ima snažan pozitivan uticaj na sreću. | <b>POTVRĐENO</b>  | Korelacija $r = 0.784$ ; univarijantni $R^2 = 0.615$ .       |
| <b>H_2:</b> Socijalni kapital (Social support) ima veći značaj od BDP-a.  | <b>POTVRĐENO</b>  | Korelacija $r = 0.835$ ; Feature Importance $\approx 42\%$ . |

|                                                                                 |                  |                                                                             |
|---------------------------------------------------------------------------------|------------------|-----------------------------------------------------------------------------|
| <b>H_3:</b> Kompletni socio-ekonomski profil objašnjava većinu varijanse sreće. | <b>POTVRĐENO</b> | Multivarijantna Linearna regresija ostvaruje $R^2 = 0.780$ .                |
| <b>Glavno pitanje:</b> <i>Da li su najbogatije zemlje ujedno i najsretnije?</i> | <b>NE NUŽNO</b>  | BDP je neophodan temelj, ali bez socijalne podrške i sloboda nije dovoljan. |

Rezultati projekta nedvosmisleno pokazuju da ekonomsko bogatstvo predstavlja značajan faktor povezan sa nacionalnom srećom, ali ne predstavlja dovoljan uslov za njeno potpuno objašnjenje. Iako je Logged GDP per capita ostvario snažnu pozitivnu povezanost sa Happiness score-om, Social support (socijalna podrška i društvena kohezija) pokazao je još izraženiju povezanost i veći ponder unutar prediktivnih modela mašinskog učenja.

Ljudsko blagostanje je kompleksan, multidimenzionalan fenomen. Ekonomski rast stvara neophodnu materijalnu osnovu i egzistencijalnu sigurnost, ali tek u kombinaciji sa snažnom socijalnom mrežom, visokim očekivanim životnim vijekom, ličnim slobodama i društvenim povjerenjem (niskom korupcijom) rezultira vrhunskim kvalitetom života.

Zbog toga, glavna poruka i zaključak ove analize glasi: **Najbogatije zemlje nisu nužno i najsretnije zemlje.**