

PREZENTACIJA ZA SASTANAK

Korelacije među podacima i train/test podjele

Jesu li neki faktori suvišni? Mijenja li se model ako podijelimo podatke drugačije?

Money vs Happiness · World Happiness Report 2023 · 137 zemalja

Linear Regression · Random Forest · XGBoost

Dva pitanja na ovom sastanku

1

Korelacije među 6 faktora

Da li su neki socio-ekonomski faktori
toliko slični da jednu kolonu treba izbaciti?

2

Više train/test podjela

80/20 nije jedini način. Šta se desi na
90/10, 70/30, 60/40 — poboljša li se model?


Glavni protokol ostaje 80/20 i svih 6 kolona. Ovo su provjere, ne lov na ljepši broj.

Prvo: ko ide sa srećom?

Faktor	Pearson r	Poruka
Social support	0.835	Najjači korelat sreće
Logged GDP per capita	0.784	Jaka pozitivna veza
Healthy life expectancy	0.746	Jaka pozitivna veza
Freedom to make life choices	0.663	Umjereno–jaka
Perceptions of corruption	−0.472	Umjerena negativna
Generosity	0.044	Praktično nula

Ovo nije pitanje o izbacivanju kolone. Korelacija $\neq$ kauzalnost. Profesorica je zatim tražila korelacije MEĐU faktorima.

Među 6 faktora: jesu li duplikati?



Jedini par $|r| \geq 0.80$

GDP $\leftrightarrow$ Healthy life expectancy

$r = 0.84$

Ostali parovi

GDP $\leftrightarrow$ Social support 0.74

Social $\leftrightarrow$ Healthy life 0.73

Generosity ≈ 0 sa svima

Prag

Sumnja na redundantnost
ako je $|r| \geq 0.80$

VIF: je li $r = 0.84$ razlog za brisanje?

Faktor	VIF	Dijagnoza
Logged GDP per capita	4.20	Umjereno, ispod 5
Healthy life expectancy	3.73	Nisko–umjereno
Social support	2.95	Nisko
Freedom to make life choices	1.59	Nisko
Perceptions of corruption	1.43	Nisko
Generosity	1.19	Skoro nezavisan

Prag za ozbiljan problem je $VIF > 10$. Najviši VIF ovdje je 4.20. Pearson r gleda parove; VIF gleda koliko se jedan faktor da objasniti ostalih pet odjednom.

Odluka: nijedna kolona nije izbačena

1

Statistika

Samo jedan par iznad 0.80. Svi VIF < 5.

2

Sadržaj

GDP i Healthy life expectancy nisu duplikati — bogatstvo vs zdravlje.

3

Modeli

Stabla (RF, XGBoost) podnose korelirane prediktore. Brisanje bi više naškodilo interpretaciji.

4

Trag u LR

Healthy life expectancy: $r = 0.75$ sa srećom, ali koeficijent samo +0.02. GDP „pojede“ efekat — bilježi se, ne briše se kolona.

Zašto više podjela, ne samo 80/20?

Glavni protokol

80/20 · 109 train / 28 test · seed 42

Šta je dodato

Omjeri 90/10, 70/30, 60/40 + isti 80/20 sa seedovima 0, 7, 42, 123

Zašto fiksni hiperparametri

Da se porede splitovi, ne sreća GridSearch-a

Kako čitati brojke

„Bolji R^2 “ na jednom holdoutu $\neq$ bolji model. Na 137 zemalja test skup lako bude lakši ili teži.

Test R^2 po omjeru (seed = 42)

Split	Train / test	LR	Random Forest	XGBoost	Naspram 80/20
90/10	123 / 14	0.623	0.493	0.581	Svi padaju
80/20	109 / 28	0.780	0.729	0.675	Baza
70/30	95 / 42	0.850	0.770	0.725	Izgleda bolje
60/40	82 / 55	0.823	0.755	0.731	Izgleda bolje

Najgore

90/10 — test ima samo 14 zemalja

Najljepši broj



70/30 · LR · $R^2 = 0.850$

Protokol

80/20 ostaje — slaže se sa CV 0.779

Gdje se model pokvario, a gdje „poboljšao“?

Does the holdout split change model quality?




Lijevo: Test R² (više = bolje). Desno: Test MAE (niže = bolje). 90% train = najgori ishod za sve modele.

Promjena Test R^2 naspram 80/20

Model	90/10	80/20 baza	70/30	60/40
Linear Regression	0.623 (−0.16)	0.780	0.850 (+0.07)	0.823 (+0.04)
Random Forest	0.493 (−0.24)	0.729	0.770 (+0.04)	0.755 (+0.03)
XGBoost	0.581 (−0.09)	0.675	0.725 (+0.05)	0.731 (+0.06)

- 90/10: nedvosmisleno pogoršanje. Mali test (14 zemalja) nije evaluacija.
- 70/30 i 60/40 dižu R^2 na ovom seedu — to može biti lakši test skup, ne bolji model.
- Na 70/30 RF/XGB imaju viši R^2 , ali MAE im je malo lošiji. „Bolje“ nije jednoznačno.
- LR je iznad stabala na svakom omjeru ovog seeda.

Isti 80/20, drugi shuffle — je li seed 42 bio sretan?



Seed	LR	RF	Prvi
0	0.619	0.635	RF
7	0.741	0.749	RF
42	0.780	0.729	LR
123	0.822	0.839	RF

LR na istom 80/20 skače od 0.62 do 0.82. Seed 42 je u gornjoj polovini, nije ekstrem. Rang modela se vrti — zato rangiramo po 5-fold CV, ne po jednom holdoutu.

Koja se ispostavila kao najbolja?

NAJVIŠI TEST R^2

70/30 · LR · 0.850

Sreća tog test skupa. Nije protokol.

NAJGORA PODJELA

90/10

Svi modeli padaju. 14 test zemalja.

NAJSTABILNIJA OCJENA

5-fold CV · LR 0.779 ± 0.038

Svaka zemlja jednom u testu.

ŠTA ZADRŽAVAMO

80/20 · seed 42

Standard. Holdout $\approx$ CV. Reproducibilno.

Šta ostaje u projektu

Svih 6 kolona

GDP i zdravlje dijele signal, ali nisu ista stvar.

80/20 + 5-fold CV

70/30 izgleda ljepše, ali to bi bilo biranje splita nakon testa.

Linearna regresija

Najbolja po CV (0.779 ± 0.038). Jednostavan model na malom uzorku.

Tri rečenice ako zapnem

KORELACIJE

„Među 6 faktora jedini par iznad 0.8 je GDP i Healthy life expectancy, $r = 0.84$. VIF je ispod 5. Kolonu nisam izbacila jer mjere različite stvari.“

PODJELE

„Na 90/10 se svi pokvare. Na 70/30 LR dođe do 0.85, ali to je sreća testa. Isti 80/20 s drugim seedom skače 0.62–0.82.“

ODLUKA

„Ostaje 80/20 i svih 6 kolona. Rang držim po 5-fold CV, gdje je linearna regresija i dalje prva.“