

PRIPREMA ZA SASTANAK

Korelacije među podacima i analiza train/test podjela

Kako predstaviti profesorici šta je urađeno, šta brojke znače,
i zašto nijedna kolona nije izbačena niti je 70/30 „pobijedio“ 80/20.

Projekat: Money vs Happiness

Podaci: World Happiness Report 2023 · 137 zemalja

Sastanak: 18. septembar 2026.

Kako koristiti ovaj dokument

Ovo nije cijeli akademski izvještaj. To je briefing za usmeno izlaganje: dva pitanja koja je profesorica eksplicitno tražila, sa tačnim brojkama iz pipeline-a, grafikona i CSV tabela. Ako zatraži detalj, uputi je na PROJECT_REPORT.md (sekcije 10.3.1 i 13.4) i fajlove u results/.

Predloženi redoslijed na sastanku (oko 8–10 minuta):

- 1 min — podsjetnik: predviđamo Happiness score iz 6 socio-ekonomskih faktora.
- 3–4 min — korelacije: prvo sa srećom, zatim među faktorima (da li izbaciti kolonu).
- 4–5 min — train/test: 90/10, 80/20, 70/30, 60/40 + različiti seedovi; gdje se model „popravio“, a gdje pokvario.
- Zatvaranje — jedna rečenica: zadržavamo svih 6 kolona i 80/20 + 5-fold CV.

Sadržaj

- 1. Korelacija među podacima — šta, kako, odluka o kolonama
- 2. Train/test podjele — svaki omjer, dobitak/gubitak, koja je „najbolja“
- 3. Cheat-sheet za sastanak — rečenice koje možeš doslovno reći

1. Korelacija među podacima

1.1 Šta je profesorica tražila

Prvo je tražila korelaciju između podataka. Zatim je precizirala: treba vidjeti korelaciju među 6 socio-ekonomskih faktora, da se utvrdi jesu li neki faktori toliko slični da jednu kolonu treba izbaciti. To nije isto što i korelacija sa srećom. Prvo pokazuje ko je povezan s ciljem. Drugo pokazuje ko je suvišan među prediktorima (multikolinearnost / redundantnost).

1.2 Dva različita pitanja — ne pomiješaj ih

Pitanje	Šta se računa	Gdje je u projektu	Zašto
Ko ide sa srećom?	Pearson r faktora sa Happiness score	heatmap cilj + 6 faktora	EDA: koji signali su jaki
Jesu li faktori duplikati?	Pearson r među 6 faktora + VIF	heatmap samo prediktori	Da li izbaciti kolonu

Tabela 1. Dvije korelacione analize u projektu. Profesorica na ovom sastanku pita za donji red.

1.3 Metoda (reci ovo ako pita „kako ste to radili“)

- Pearsonova korelacija mjeri linearnu povezanost. Raspon: -1 (jaka negativna) do $+1$ (jaka pozitivna). Blizu 0 = nema linearne veze.
- Prag za sumnju na redundantnost: $|r| \geq 0.80$. To je uobičajeno pravilo palca, nije zakon.
- Dodatna provjera: VIF (Variance Inflation Factor). Za svaki faktor i računa se $VIF_i = 1 / (1 - R_i^2)$, gdje se taj faktor regresira na ostalih 5. Uobičajeni prag za ozbiljan problem: $VIF > 10$. $VIF < 5$ smatra se prihvatljivim.
- Kod: `src/eda.py` → `analyze_predictor_redundancy()`. Tabele: `results/predictor_correlations.csv`, `results/predictor_vif.csv`.

1.4 Korelacije sa Happiness score (kontekst, 30 sekundi)

Ovo nije pitanje o izbacivanju kolone, ali profesorica često krene odavde. To su Pearson r vrijednosti prema cilju (WHR 2023):


Faktor	Pearson r sa Happiness score	Interpretacija
Social support	0.835	Najjača pozitivna veza
Logged GDP per capita	0.784	Jaka pozitivna veza
Healthy life expectancy	0.746	Jaka pozitivna veza
Freedom to make life choices	0.663	Umjereno–jaka pozitivna
Perceptions of corruption	−0.472	Umjerena negativna veza
Generosity	0.044	Praktično nula — nema linearne veze

Tabela 2. Koji faktori idu sa srećom. Socijalna podrška je statistički jača od GDP-a. Generosity gotovo da ne postoji kao linearni prediktor.

Važna rečenica: korelacija nije kauzalnost. Ovo je presjek jedne godine (137 zemalja), ne dokaz da povećanje socijalne podrške uzrokuje sreću.

1.5 Korelacije MEĐU 6 faktora — srž njenog pitanja

Ovdje cilj (Happiness score) nije u matrici. Gledamo samo prediktore: jesu li dva faktora statistički ista priča. Zelenije = jača pozitivna sličnost, narančasto = negativna veza.



Slika 1. Pearson matrica samo među prediktorima. Tamnozeleno polje GDP ↔ Healthy life expectancy (0.84) je jedini par iznad praga 0.80.

1.6 Svi parovi, sortirani po sličnosti

Faktor 1	Faktor 2	r	r ≥ 0.80?	Šta to znači
Logged GDP per capita	Healthy life expectancy	0.836	DA	Jedini kandidat za izbacivanje
Logged GDP per capita	Social support	0.738	ne	Slični, ali ispod praga
Social support	Healthy life expectancy	0.725	ne	Slični, ali ispod praga
Social support	Freedom to make life choices	0.542	ne	Umjereno
Logged GDP per capita	Freedom to make life choices	0.451	ne	Umjereno
Logged GDP per capita	Perceptions of corruption	-0.437	ne	Bogatije zemlje: niža percepcija korupcije
Healthy life expectancy	Freedom to make life choices	0.414	ne	Slabo–umjereno
Healthy life expectancy	Perceptions of corruption	-0.404	ne	Slabo–umjereno
Freedom to make life choices	Perceptions of corruption	-0.384	ne	Slabo–umjereno
Social support	Perceptions of corruption	-0.272	ne	Slabo
Freedom to make life choices	Generosity	0.170	ne	Skoro nezavisno
Logged GDP per capita	Generosity	-0.156	ne	Skoro nezavisno
Healthy life expectancy	Generosity	-0.134	ne	Skoro nezavisno

Faktor 1	Faktor 2	r	r ≥ 0.80?	Šta to znači
Generosity	Perceptions of corruption	-0.123	ne	Skoro nezavisno
Social support	Generosity	0.037	ne	Potpuno drugi signal

Tabela 3. Petnaest parova ($C(6,2) = 15$). Samo jedan prelazi prag.

1.7 VIF — da li je $r = 0.84$ dovoljan razlog za brisanje?

Pearson r gleda parove. VIF gleda koliko se jedan faktor da objasniti svim ostalima odjednom. To je stroža, standardna dijagnostika za linearnu regresiju.

Faktor	VIF	R^2 na ostalih 5	Dijagnoza
Logged GDP per capita	4.20	0.76	Umjereno, ispod 5
Healthy life expectancy	3.73	0.73	Nisko—umjereno
Social support	2.95	0.66	Nisko
Freedom to make life choices	1.59	0.37	Nisko
Perceptions of corruption	1.43	0.30	Nisko
Generosity	1.19	0.16	Nisko — skoro nezavisan

Tabela 4. Nijedan VIF nije ni blizu 10. Čak ni GDP (najviši) nije iznad 5.

1.8 Odluka: nijedna kolona nije izbačena

Argumenti, redom, ako te prekine:

- Statistika: jedini par iznad 0.80 je GDP $\leftrightarrow$ Healthy life expectancy ($r = 0.836$). Svi VIF < 5.
- Sadržaj: to nisu duplikati. Jedno mjeri materijalno bogatstvo, drugo zdravstveni ishod. Bogatije zemlje imaju duži zdrav život, ali to su različiti koncepti.
- Modeli: Random Forest i XGBoost podnose korelirane prediktore bolje od linearne regresije. Brisanje kolone bi više naškodilo interpretaciji nego što bi „očistilo“ stabla.
- Trag u LR: Healthy life expectancy ima $r = 0.746$ sa srećom, ali LR koeficijent samo +0.020. Dio efekta „pojede“ GDP. To je klasičan znak multikolinearnosti — bilježi se, ne briše se automatski kolona.
- Generosity nije kandidat za izbacivanje zbog sličnosti s drugima ($r \approx 0$), nego je slab prediktor cilja. To je druga odluka, i u projektu je zadržana jer je WHR standardni faktor.

Šta reći profesorici — korelacije (30 sekundi)

„Uradila sam Pearsonovu matricu među svih 6 faktora. Jedini par iznad 0.8 je GDP i Healthy life expectancy, $r = 0.84$. VIF je svugdje ispod 5, najviši je GDP 4.20. Nisam izbacivala kolonu jer mjere različite stvari, a prag za VIF je 10. Generosity je nezavisna od ostalih. Socijalna podrška je i dalje najjači korelat sreće ($r = 0.84$), ispred GDP-a.“

2. Train/test podjele

2.1 Šta je profesorica tražila

Glavni protokol je bio 80/20 (109 zemalja za trening, 28 za test, random_state=42). Rekla je da podjelu uradim na više različitih načina da se vidi hoće li se model poboljšati ili pokvariti. To je pitanje o robustnosti, ne o traženju omjera koji da najljepši Test R².

2.2 Šta je tačno urađeno

- Glavni izvještaj ostaje 80/20, seed 42 — to se nije mijenjalo.
- Četiri omjera, isti seed 42: 90/10, 80/20, 70/30, 60/40.
- Četiri shuffle-a istog 80/20 omjera: seedovi 0, 7, 42, 123 — da se vidi da li je baš taj 80/20 bio sretan.
- Tri modela: Linear Regression, Random Forest, XGBoost. Za ovu usporedbu su fiksni hiperparametri (bez GridSearch-a), da se porede splitovi, ne sreća tuninga.
- Kod: src/model.py → run_split_sensitivity(). CSV: split_ratio_metrics.csv, split_seed_metrics.csv.
- Linearna regresija na 80/20 seed 42 ima isti Test R² kao u glavnoj tabeli (0.780), jer LR nema tuning. RF/XGBoost u ovoj usporedbi su malo drugačiji od „tuned“ brojki u glavnom izvještaju — to reci ako uporedi tabele.

2.3 Kako čitati „poboljšao se / pokvario se“

Bazna linija je 80/20, seed 42. „Poboljšanje“ ovdje znači viši Test R² / niži MAE na tom holdoutu, ne da je model naučio bolju pravu vezu. Na 137 zemalja, koje zemlje upadnu u test skup može promijeniti R² za više od 0.20. Zato brojke niže opisuju šta se desilo na tom splitu, a zaključak na kraju kaže šta od toga smijemo tretirati kao bolji protokol.

2.4 Svaka podjela — šta se radilo i šta se dobilo

A) 90/10 — 123 train / 14 test

Najviše podataka za učenje, ali test ima samo 14 zemalja. To je statistički premalo: jedan ili dva outliera pokvare cijeli R².

Model	Test R ²	Test MAE	Naspram 80/20	Ocjena
Linear Regression	0.623	0.483	R ² -0.157 · MAE +0.077	Jako pogoršanje
Random Forest	0.493	0.511	R ² -0.236 · MAE +0.088	Najveći pad
XGBoost	0.581	0.513	R ² -0.094 · MAE +0.032	Pogoršanje

Tabela 5. 90/10 je najgora podjela za sva tri modela. Više treninga ovdje nije pomoglo, jer test nije pouzdan. Ako pita „zašto ne 90/10 kad ima više train podataka?“, zato što ocjenjujemo model na 14 tačaka — to nije evaluacija, to je loterija.

B) 80/20 — 109 train / 28 test (glavni protokol, seed 42)

Standardni akademski holdout. Dovoljno testa da R² ne stoji na 14 tačaka, dovoljno treninga za 6 faktora.

Model	Test R ²	Test MAE	Uloga
Linear Regression	0.780	0.406	Najbolji na ovom splitu; isti broj kao glavni izvještaj
Random Forest	0.729	0.423	Drugi (untuned u ovoj tabeli)

Model	Test R ²	Test MAE	Uloga
XGBoost	0.675	0.481	Treći (untuned; tuned u glavnom izvještaju je 0.751)

Tabela 6. Referentna tačka. 5-fold CV za LR je 0.779 ± 0.038 — skoro identično ovom holdoutu, što je dobar znak da seed 42 nije lud.

C) 70/30 — 95 train / 42 test

Više testa, manje treninga. Na ovom seedu svi modeli imaju viši Test R² nego na 80/20. To izgleda kao pobjeda — i to treba odmah demistificirati.

Model	Test R ²	Test MAE	Naspram 80/20	Ocjena
Linear Regression	0.850	0.386	R ² +0.070 · MAE −0.021	Najviši R ² od svih omjera
Random Forest	0.770	0.432	R ² +0.041 · MAE +0.009	R ² gore, MAE malo gore
XGBoost	0.725	0.489	R ² +0.050 · MAE +0.008	R ² gore, MAE malo gore

Tabela 7. 70/30 je holdout s najljepšim Test R² (LR 0.850). To NIJE dokaz da je 70/30 bolji protokol. Test skup od 42 zemlje na seedu 42 bio je „lakši“ (manje teških slučajeva). RF i XGB imaju viši R² ali MAE im je čak malo lošiji — već tu se vidi da „bolje“ nije jednoznačno.

D) 60/40 — 82 train / 55 test

Još veći test, još manji train (samo 82 zemlje za 6 faktora). LR i dalje izgleda bolje od 80/20 na ovom seedu, ali slabije od 70/30. Stabla ostaju iza LR.

Model	Test R ²	Test MAE	Naspram 80/20	Ocjena
Linear Regression	0.823	0.392	R ² +0.043 · MAE −0.014	Izgleda bolje od 80/20, gore od 70/30
Random Forest	0.755	0.401	R ² +0.026 · MAE −0.022	Blago bolje
XGBoost	0.731	0.431	R ² +0.056 · MAE −0.050	R ² i MAE bolji nego na 80/20


Tabela 8. 60/40 nije katastrofa, ali gubi train podatke bez jasnog sistematskog dobitka.

2.5 Pregled: gdje se pogoršalo, gdje „poboljšalo“

Promjena Test R^2 u odnosu na 80/20 (seed 42). Minus = pogoršanje, plus = viši R^2 na tom holdoutu.

Model	90/10	80/20 (baza)	70/30	60/40
Linear Regression	0.623 (-0.16)	0.780	0.850 (+0.07)	0.823 (+0.04)
Random Forest	0.493 (-0.24)	0.729	0.770 (+0.04)	0.755 (+0.03)
XGBoost	0.581 (-0.09)	0.675	0.725 (+0.05)	0.731 (+0.06)

Tabela 9. 90/10 je pad za sve modele. 70/30 i 60/40 dižu R^2 na ovom seedu.



Slika 2. Lijevo R^2 (više = bolje), desno MAE (niže = bolje). X-osa je udio treninga: 90 → 60. Svi modeli padaju na 90% train (mali test). LR je iznad ostalih na svakom omjeru ovog seeda.

Jedna rečenica po omjeru:


- 90/10: svi modeli se pokvare. Najgori ishod. Ne koristiti.
- 80/20: stabilna baza. LR 0.780 slaže se sa CV 0.779.
- 70/30: najviši R^2 (LR 0.850) — izgleda kao poboljšanje, ali je sreća testa.
- 60/40: i dalje izgleda bolje od 80/20 na ovom seedu, ali slabije od 70/30; manje podataka za učenje.

2.6 Isti 80/20, drugi shuffle — da nije 80/20 bio sretan?

Omjer ostaje 80/20, mijenja se samo koji slučajni 28 zemalja idu u test. Ako je model zaista stabilan, R^2 ne smije skakati kao loto.

Seed	LR R^2	RF R^2	XGB R^2	Ko je prvi?	Naspram seed 42 (LR)
0	0.619	0.635	0.607	Random Forest	LR -0.161 (pogoršanje)
7	0.741	0.749	0.737	Random Forest	LR -0.039
42 (glavni)	0.780	0.729	0.675	Linear Regression	baza
123	0.822	0.839	0.798	Random Forest	LR +0.042 (izgleda bolje)

Tabela 10. LR Test R^2 na istom 80/20 ide od 0.619 do 0.822. Seed 42 (0.780) je u gornjoj polovini, nije ni najsretniji ni najnesretniji. Na 3 od 4 seeda Random Forest čak nadmašuje LR — zato se rang ne smije objavljivati s jednog holdouta.



Slika 3. Isti omjer, četiri shuffle-a. Visina stubova skače — to je cijela poenta malog uzorka.

Šta da zapamtiš sa ove slike: seed 0 je loš za sve; seed 123 je sretan (čak RF ispred LR); seed 42 je u sredini—gore. Zato 80/20 nije prevara, ali jedan holdout nije dovoljan za rang modela.

2.7 Koja se ispostavila kao najbolja?

Ovjde moraš razdvojiti najljepši jedan broj od najboljeg protokola. Ako ih pomiješaš, profesorica će s pravom reći da juriš R^2 .

Kriterij	Pobjednik	Zašto to NIJE / JESTE odgovor
Najviši Test R^2 (omjeri)	70/30 · LR · 0.850	Samo ovaj seed i ovaj test skup. Ne ponavlja se kao pravilo.
Najviši Test R^2 (seedovi)	80/20 seed 123 · RF · 0.839	Još jedan sretan shuffle. RF tu pobjeđuje LR — rang nije stabilan.
Najgora podjela	90/10 · svi modeli padaju	14 test zemalja. Ovo je jedini nedvosmisleno loš izbor.
Najstabilnija ocjena kvaliteta	5-fold CV · LR 0.779 ± 0.038	Svaka zemlja jednom bude u test foldu. Zato rangiramo po CV.
Preporučeni holdout	80/20 · seed 42	Standard, nije ekstrem, LR holdout ≈ CV, reproducibilan.

Tabela 11. Konačni odgovor na „koja je najbolja podjela?“.

Zaključak koji treba izgovoriti: najviši broj je 70/30, ali najbolja odluka je ostaviti 80/20 i oslanjanje na 5-fold CV. Model se nije sistematski poboljšao većim ili manjim testom — mijenjao se sastav 14–55 zemalja u testu. Na malom uzorku (137) holdout je bučan; CV je mirniji.

Šta reći profesorici — podjele (45 sekundi)

„Pored 80/20 uradila sam 90/10, 70/30 i 60/40, plus isti 80/20 s četiri različita seeda. Na 90/10 se svi modeli pokvare — test ima samo 14 zemalja. Na 70/30 linearna regresija dođe do R^2 0.85, što izgleda bolje od 0.78, ali to je sreća tog test skupa, ne bolji model. Isti 80/20 s drugim seedom skače od 0.62 do 0.82, a ponekad Random Forest pobijedi. Zato nisam mijenjala protokol: ostaje 80/20, a rang modela držim po 5-fold CV, gdje je linearna regresija i dalje prva (0.779 ± 0.038).“

2.8 Ako te gura da ipak pređeš na 70/30

- Možeš reći da si 70/30 ispitala i da ga ne krijete — tabela je u izvještaju.

- Preći na 70/30 samo zato što je R^2 veći bilo bi data snooping: biraš split nakon što vidiš test.
- Ako insistira na drugom omjeru, poštena alternativa nije 70/30 nego ponavljanje CV / više seedova, što je već urađeno.
- Glavni naučni nalaz ($LR \geq$ stabla na ovom malom linearno-ish skupu) opstaje na svim omjerima ovog seeda: LR je uvijek iznad RF i XGB u Tabeli 9.

3. Cheat-sheet za sastanak

Ova stranica je za štampu ili za ekran pored sebe. Ako zapneš, čitaj okvire redom.

Rečenica 1 — uvod

„Imam dva dopunjena eksperimenta: korelacije među 6 faktora (da li izbaciti kolonu) i više train/test podjela (da li 80/20 laže).“

Rečenica 2 — korelacije

„Među prediktorima jedini par iznad 0.8 je GDP i Healthy life expectancy, $r = 0.84$. VIF je ispod 5. Kolonu nisam izbacila jer su to različiti koncepti. Generosity je nezavisna. Sa srećom najjače ide socijalna podrška (0.84), pa GDP (0.78).“

Rečenica 3 — podjele

„90/10 se pokvari. 70/30 izgleda najbolje (LR 0.85), ali to je sreća testa. Isti 80/20 s drugim seedom skače 0.62–0.82. Ostaje 80/20 + 5-fold CV.“

Rečenica 4 — zatvaranje

„Dakle: svih 6 kolona ostaje, 80/20 ostaje, linearna regresija i dalje najbolji model po CV. Nisam mijenjala protokol zbog jednog lijepog holdout broja.“

Brojevi koje treba znati napamet

Stavka	Broj
Zemlje u skupu	137
Faktori	6
Najjači korelati sreće	Social support 0.835 · GDP 0.784
Jedini par $ r \geq 0.80$	GDP $\leftrightarrow$ Healthy life expectancy 0.836
Najviši VIF	GDP 4.20 (prag 10)
Izbacene kolone	nijedna
Glavni split	80/20 · 109 / 28 · seed 42
LR Test R^2 na 80/20	0.780
LR 5-fold CV R^2	0.779 $\pm$ 0.038
90/10 LR Test R^2	0.623 (pogoršanje)
70/30 LR Test R^2	0.850 (izgleda bolje, nije protokol)
60/40 LR Test R^2	0.823
80/20 LR R^2 po seedovima	0.619 · 0.741 · 0.780 · 0.822

Stavka	Broj
Preporuka	svih 6 kolona · 80/20 · rang po CV

Tabela 12. Mini-memorija za sastanak.

Gdje su dokazi u projektu

- Kod korelacija: src/eda.py (analyze_predictor_redundancy)
- Kod podjela: src/model.py (run_split_sensitivity)
- Izvještaj: PROJECT_REPORT.md §10.3.1 i §13.4
- Grafikoni: results/plots/predictor_correlation_heatmap.png, split_ratio_comparison.png, split_seed_comparison.png
- Tabele: results/predictor_correlations.csv, predictor_vif.csv, split_ratio_metrics.csv, split_seed_metrics.csv
- Dashboard: donji dio — heatmap prediktora i linija Test R^2 po omjeru

Ako na kraju pita šta je naučni rezultat ova dva eksperimenta, a ne šta je procedura: bogatstvo i zdravlje dijele informaciju, ali nisu ista stvar; holdout na 137 zemalja je nestabilan, pa jednostavan model + CV ostaju poštenija priča od lovljenja omjera.